



# **Certified Tester Specialist Level Testing with Generative AI (CT-GenAI) Syllabus**

Version 1.1

한글 Korean 1.0

---

International Software Testing Qualifications Board

---

(사) KSTQB

Korean Software Testing Qualifications Board

International Software Testing Qualifications Board

## 저작권 고지 Copyright Notice

Copyright Notice © International Software Testing Qualifications Board (이하 ISTQB®)

ISTQB® 는 국제 소프트웨어 테스트 자격 위원회의 등록 상표입니다.

Copyright © 2025, 저자 Abbas Ahmad, Gualtiero Bazzana, Alessandro Collino, Olivier Denoo, and Bruno Legeard.

저자들은 이로써 저작권을 ISTQB®에 양도합니다. 저자들(현재 저작권자)과 ISTQB®(미래 저작권자)는 다음 사용 조건에 동의했습니다:

비상업적 용도로 본 문서의 발췌문을 복사할 경우 출처를 명시해야 합니다.

모든 인증 교육 제공 기관은 저자들과 ISTQB®를 해당 실러버스의 출처 및 저작권자로 명시하는 조건 하에 본 실러버스를 교육 과정의 기초로 사용할 수 있으며, 해당 교육 과정 광고는 각 국가의 ISTQB® 회원위원회(Member Board)로부터 교육 자료에 대한 공식 인증을 받은 후에만 실러버스를 언급할 수 있습니다.

모든 개인 또는 단체는 저자들과 ISTQB®를 해당 실러버스의 출처 및 저작권자로 명시하는 조건 하에 본 실러버스를 논문 및 서적의 기초로 사용할 수 있습니다.

본 실러버스의 다른 모든 사용은 ISTQB®의 서면 승인을 먼저 받지 않고는 금지됩니다.

모든 ISTQB® 국가회원위원회는 번역된 버전의 실러버스에 위에서 언급된 저작권 고지를 공지하는 조건 하에 본 실러버스를 해당 국가의 언어로 번역할 수 있습니다.

## 목 차

|                                                       |           |
|-------------------------------------------------------|-----------|
| <b>0. 서론 Introduction.....</b>                        | <b>6</b>  |
| <b>제 1 장 소프트웨어 테스트를 위한 생성형 AI 소개.....</b>             | <b>10</b> |
| 1.1 생성형 AI의 기초 및 핵심 개념.....                           | 11        |
| 1.1.1. AI 스펙트럼: 심볼릭 AI, 고전적 머신 러닝, 딥 러닝 및 생성형 AI..... | 11        |
| 1.1.2. 생성형 AI 및 LLM의 기초.....                          | 12        |
| 1.1.3. 파운데이션, 명령어 튜닝, 추론 LLM.....                     | 13        |
| 1.1.4. 멀티모달 LLM과 비전-언어 모델.....                        | 13        |
| 1.2 소프트웨어 테스트에서 생성형 AI 활용: 핵심 원칙.....                 | 14        |
| 1.2.1. 테스트 작업을 위한 주요 LLM 역량.....                      | 15        |
| 1.2.2. 소프트웨어 테스트를 위한 AI 챗봇과 LLM 기반 테스트 애플리케이션.....    | 15        |
| <b>제 2 장 효과적인 소프트웨어 테스트를 위한 프롬프트 엔지니어링.....</b>       | <b>17</b> |
| 2.1 효과적인 프롬프트 개발.....                                 | 19        |
| 2.1.1. 소프트웨어 테스트에서 생성형 AI를 위한 프롬프트 구조.....            | 19        |
| 2.1.2. 소프트웨어 테스트를 위한 핵심 프롬프팅 기법.....                  | 20        |
| 2.1.3. 시스템 프롬프트와 사용자 프롬프트.....                        | 21        |
| 2.2 소프트웨어 테스트 작업에 프롬프트 엔지니어링 기법 적용하기.....             | 22        |
| 2.2.1. 생성형 AI를 활용한 테스트 분석.....                        | 22        |
| 2.2.2. 생성형 AI를 활용한 테스트 설계 및 구현.....                   | 24        |
| 2.2.3. 생성형 AI를 활용한 자동화된 리그레션 테스트.....                 | 25        |
| 2.2.4. 생성형 AI를 활용한 테스트 모니터링과 제어.....                  | 27        |
| 2.2.5. 소프트웨어 테스트를 위한 프롬프팅 기법 선택.....                  | 28        |
| 2.3 생성형 AI 결과 평가와 소프트웨어 테스트 작업을 위한 프롬프트 개선.....       | 29        |
| 2.3.1. 테스트 작업에 대한 생성형 AI 결과 평가 메트릭.....               | 29        |
| 2.3.2. 프롬프트 평가와 반복적 개선 기법.....                        | 30        |

|                                                       |           |
|-------------------------------------------------------|-----------|
| <b>제 3 장 소프트웨어 테스트에서 생성형 AI의 리스크 관리</b>               | <b>32</b> |
| 3.1 환각, 추론 오류, 편향                                     | 34        |
| 3.1.1. 생성형 AI의 환각, 추론 오류, 편향                          | 34        |
| 3.1.2. LLM 출력에서 환각, 추론 오류, 편향 식별하기                    | 34        |
| 3.1.3. 소프트웨어 테스트 작업에서 GenAI 환각, 추론 오류, 편향 완화 기법       | 36        |
| 3.1.4. LLM의 비결정론적 행동 완화                               | 36        |
| 3.2 소프트웨어 테스트에서 생성형 AI의 데이터 프라이버시와 보안 리스크             | 37        |
| 3.2.1. 생성형 AI 사용 관련 데이터 프라이버시와 보안 리스크                 | 37        |
| 3.2.2. 테스트 프로세스와 도구에서 생성형 AI의 데이터 프라이버시 및 취약점         | 38        |
| 3.3 소프트웨어 테스트에서 생성형 AI의 에너지 소비와 환경 영향                 | 39        |
| 3.3.1. GenAI 사용이 에너지 소비와 CO2 배출에 미치는 영향               | 39        |
| 3.4 AI 규정, 표준 및 모범 사례 프레임워크                           | 40        |
| 3.4.1. 소프트웨어 테스트에서 GenAI와 관련된 AI 규정, 표준, 프레임워크        | 40        |
| <b>제 4 장 소프트웨어 테스트를 위한 LLM 기반 테스트 인프라</b>             | <b>42</b> |
| 4.1 LLM 기반 테스트 인프라를 위한 아키텍처 접근법                       | 43        |
| 4.1.1. LLM 기반 테스트 인프라의 주요 아키텍처 구성요소와 개념               | 43        |
| 4.1.2. 검색 증강 생성 (Retrieval-Augmented Generation, RAG) | 44        |
| 4.1.3. 테스트 프로세스 자동화에서 LLM 기반 에이전트의 역할 및 적용            | 45        |
| 4.2 미세 조정과 LLMOps: 소프트웨어 테스트를 위한 생성형 AI 운영화           | 46        |
| 4.2.1. 특정 테스트 작업을 위한 언어 모델 미세 조정                      | 46        |
| 4.2.2. 테스트 작업을 위한 LLM 배포 및 관리에서 LLMOps의 역할            | 47        |
| <b>제 5 장 테스트 조직에서 생성형 AI 배포 및 통합</b>                  | <b>48</b> |
| 5.1 소프트웨어 테스트에서 생성형 AI 도입을 위한 로드맵                     | 49        |
| 5.1.1. 새도우 AI의 리스크                                    | 49        |
| 5.1.2. 소프트웨어 테스트에서 생성형 AI 전략 수립 시 필수 고려 사항            | 49        |
| 5.1.3. 소프트웨어 테스트 작업을 위한 LLM/SLM 선택                    | 50        |

|                                           |           |
|-------------------------------------------|-----------|
| 5.1.4. 테스트 조직에서 생성형 AI 도입의 주요 단계 .....    | 50        |
| 5.2 소프트웨어 테스트를 위한 생성형 AI 도입 시 변화 관리 ..... | 51        |
| 5.2.1. 생성형 AI 활용 테스트의 필수 기술 및 지식 .....    | 51        |
| 5.2.2. 테스트팀 내 생성형 AI 역량 구축 .....          | 52        |
| 5.2.3. AI 지원 테스트 조직에서의 테스트 프로세스 진화 .....  | 52        |
| <br>                                      |           |
| <b>6. 참고 문헌.....</b>                      | <b>53</b> |
| <b>부록 .....</b>                           | <b>55</b> |

## 0. 서론 Introduction

### 0.1 실러버스의 목적

이 실러버스는 국제 소프트웨어 테스트 자격 위원회(ISTQB®)의 '생성형 AI 활용 테스트(CT-GenAI)' 자격증의 기초를 이룹니다. ISTQB®는 다음과 같은 목적으로 본 실러버스를 제공합니다:

1. 국가 자격위원회가 자국어로 번역하고 교육 제공 기관을 인증할 수 있도록 지원
2. 인증 기관이 본 실러버스의 학습 목표에 맞는 시험 문제를 자국어로 출제할 수 있도록 지원
3. 교육 제공 기관이 교육 자료를 제작하고 적절한 교수법을 결정할 수 있도록 지원
4. 자격 응시자가 (교육 과정의 일부 또는 독학으로) 인증 시험을 준비할 수 있도록 지원
5. 국제 소프트웨어 및 시스템 엔지니어링 커뮤니티가 소프트웨어 및 시스템 테스트 전문가를 양성하고, 서적과 논문의 기초 자료로 활용할 수 있도록 지원

### 0.2 생성형 AI를 활용한 소프트웨어 테스트

생성형 AI 활용 테스트 자격은 소프트웨어 테스트에 생성형 AI(GenAI)를 사용하는 모든 관련자를 대상으로 합니다. 여기에는 테스터, 테스트 분석가, 테스트 자동화 엔지니어, 테스트 관리자, 사용자 인수 테스터 및 소프트웨어 개발자와 같은 역할이 포함됩니다.

본 생성형 AI 활용 테스트 자격은 프로젝트 관리자, 품질 관리자, 소프트웨어 개발 관리자, 업무 대표자, IT 책임자 및 경영 컨설턴트와 같이 생성형 AI를 활용한 소프트웨어 테스트에 대한 기본적인 이해를 원하는 모든 사람에게도 적합한 자격증입니다.

### 0.3 테스터를 위한 커리어 패스

ISTQB® 자격제도는 테스트 전문가의 경력 모든 단계에서 지식의 폭과 깊이를 모두 제공하며 지원합니다. ISTQB® 인증 테스터 생성형 AI 활용 테스트 자격을 취득한 개인은 코어 어드밴스드 레벨 이상의 자격증 레벨에도 관심을 가질 수 있습니다.

## 0.4 비즈니스 성과

여기에서는 생성형 AI 활용 테스트 자격을 취득한 응시자에게 기대되는 비즈니스 성과를 나열합니다.

| ID        | 비즈니스 성과                                                 |
|-----------|---------------------------------------------------------|
| GenAI-BO1 | 생성형 AI의 기본 개념, 역량 및 한계를 이해한다.                           |
| GenAI-BO2 | 소프트웨어 테스트를 위해 거대 언어 모델을 프롬프팅하는 실용적인 기술을 개발한다.           |
| GenAI-BO3 | 소프트웨어 테스트에 생성형 AI를 사용할 때의 리스크와 완화 방안에 대한 통찰력을 얻는다.      |
| GenAI-BO4 | 소프트웨어 테스트를 위한 생성형 AI 솔루션의 적용 사례에 대한 통찰력을 얻는다.           |
| GenAI-BO5 | 조직 내 소프트웨어 테스트를 위한 생성형 AI 전략 및 로드맵의 정의와 구현에 효과적으로 기여한다. |

## 0.5 시험 가능한 학습 목표, 실습 목표 및 인지 지식 수준

학습 및 실습 목표는 비즈니스 성과를 지원하며 생성형 AI 활용 테스트에 대한 인증 시험을 만드는 데 사용됩니다.

일반적으로, 서론, 실습 목표 및 부록을 제외한 본 실러버스의 모든 내용은 K1, K2, K3 수준에서 시험에 출제될 수 있습니다.

시험 문제는 K1 수준의 키워드(아래 참조) 또는 모든 K-레벨의 학습 목표에 대한 지식수준을 확인합니다.

구체적인 학습 목표 수준은 각 장의 시작 부분에 표시되며 다음과 같이 분류됩니다:

- K1: 기억하기
- K2: 이해하기
- K3: 적용하기

학습 목표에 대한 추가 세부 정보와 예시는 부록 A에 나와 있습니다.

장 제목 바로 아래에 키워드로 나열된 모든 용어는 학습 목표에 명시적으로 언급되지 않았더라도 기억해야 합니다.

구체적인 실습 목표(HO)는 각 장의 시작 부분에 표시됩니다. 각 HO는 K2 또는 K3 수준의 LO와 연결되어 있으며, 실습을 통해 학습을 구체화하는 것을 목표로 합니다. HO의 수준은 다음과 같이 분류됩니다:

- H0: 실습의 라이브 데모 또는 녹화된 비디오를 포함할 수 있습니다. 이것은 교육생이 직접 수행하는 것이 아니므로 엄밀히 말해 실습은 아닙니다.

- H1: 안내된 실습. 교육생들은 강사가 수행하는 일련의 단계를 따릅니다.
- H2: 힌트가 있는 실습. 교육생은 주어진 시간 내에 실습을 해결할 수 있도록 관련 힌트가 있는 실습을 받습니다.

## 0.6 인증 테스터 생성형 AI 활용 테스트 자격 시험

인증 테스터 생성형 AI 활용 테스트 자격 시험은 본 실러버스를 기반으로 합니다. 시험 문제에 대한 답변은 본 실러버스의 여러 섹션에 기반한 자료의 사용을 요구할 수 있습니다. 서론, 실습 목표 및 부록을 제외한 실러버스의 모든 섹션은 시험 범위에 포함됩니다. 표준, 서적 및 논문은 참고 자료로 포함되지만, 실러버스 자체에 요약된 내용 이상으로는 시험에 출제되지 않습니다.

자세한 내용은 '인증 테스터 생성형 AI 활용 테스트를 위한 시험 구조 및 규칙 V1.0' 문서를 참조하십시오.

참고: ISTQB® 파운데이션 레벨 자격증은 ISTQB® 인증 테스터 생성형 AI 활용 테스트 자격 시험에 응시하기 전에 취득해야 합니다.

## 0.7 인증

ISTQB® 국가자격위원회는 교육 과정 자료가 본 실러버스를 따르는 교육 제공 기관을 인증할 수 있습니다. 인증된 과정은 본 실러버스를 준수하는 것으로 인정되며, 과정의 일부로 ISTQB® 시험을 포함할 수 있습니다.

## 0.8 표준 처리

품질 특성 및 소프트웨어 테스트와 관련된 표준, 즉 파운데이션 레벨 실러버스에서 참조된 IEEE 및 ISO와 같은 표준이 있습니다. 이러한 참조의 목적은 프레임워크를 제공하거나 독자가 원하는 경우 추가 정보의 출처를 제공하는 것입니다. 실러버스는 표준 문서를 참조로 사용하고 있으며, 표준 문서 자체는 시험 대상이 아님을 유의하십시오.

## 0.9 상세 수준

본 실러버스의 상세 수준은 국제적으로 일관된 과정과 시험을 가능하게 합니다. 이러한 목표를 달성하기 위해 실러버스는 다음으로 구성됩니다:

- ISTQB® 인증 테스터 생성형 AI 활용 테스트 자격의 의도를 설명하는 일반적인 교육 목표
- 수강생이 기억해야 할 용어 목록

- 각 지식 영역에 대한 학습 목표, 달성해야 할 인지 학습 결과 설명
- 인정된 문헌이나 표준과 같은 출처를 참조하는 주요 개념 설명
- 학습을 지원하기 위한 권장 실습에 대한 각 실습 목표 설명

## 0.10 본 실러버스의 구성

시험 가능한 내용이 포함된 장은 5개입니다. 각 장의 최상위 제목은 해당 장의 시간을 명시합니다. 인증된 교육 과정의 경우, 실러버스는 최소 13.6시간의 교육을 요구하며, 5개 장에 걸쳐 다음과 같이 분배됩니다:

- 1장: 소프트웨어 테스트를 위한 생성형 AI 소개 (100분)
- 2장: 효과적인 소프트웨어 테스트를 위한 프롬프트 엔지니어링 (365분)
- 3장: 소프트웨어 테스트에서 생성형 AI의 리스크 관리 (160분)
- 4장: 소프트웨어 테스트를 위한 LLM 기반 테스트 인프라 (110분)
- 5장: 테스트 조직에서 생성형 AI 배포 및 통합 (80분)

|                                      |             |
|--------------------------------------|-------------|
| <b>제 1 장 소프트웨어 테스트를 위한 생성형 AI 소개</b> | <b>100분</b> |
|--------------------------------------|-------------|

## 생성형 AI 관련 특정 용어

AI 챗봇(AI chatbot), 컨텍스트 창(context window), 딥 러닝(deep learning), 임베딩(embedding), 피처(feature), 파운데이션 LLM(foundation LLM), 생성형 AI(generative AI), 생성형 사전 훈련 트랜스포머(generative pre-trained transformer), 명령어 튜닝 LLM(instruction-tuned LLM), 거대 언어 모델(large language model), 머신 러닝(machine learning), 멀티모달 모델(multimodal model), 추론 LLM(reasoning LLM), 심볼릭 AI(symbolic AI), 토큰화(tokenization), 트랜스포머(transformer)

## 1장 학습목표:

### 1.1 생성형 AI의 기초 및 핵심 개념

- GenAI-1.1.1 (K1) AI의 여러 유형(심볼릭 AI, 고전적 머신 러닝, 딥 러닝, 생성형 AI)을 상기한다.
- GenAI-1.1.2 (K2) 생성형 AI와 거대 언어 모델의 기초를 설명한다.
- HO-1.1.2 (H1) 소프트웨어 테스트 작업을 위해 LLM을 사용할 때 토큰화 및 토큰 수 평가를 실습한다.
- GenAI-1.1.3 (K2) 파운데이션, 명령어 튜닝, 추론 LLM을 구별한다.
- GenAI-1.1.4 (K2) 멀티모달 LLM 모델을 사용해 주어진 테스트 업무를 다루는 프롬프트를 작성하고 실행한다.
- HO-1.1.4 (H1) 소프트웨어 테스트 작업을 위해 텍스트와 이미지 입력을 모두 사용하는 멀티모달 LLM용 프롬프트를 작성하고 실행한다.

### 1.2 소프트웨어 테스트에서 생성형 AI 활용: 핵심 원칙

- GenAI-1.2.1 (K2) 테스트 작업을 위한 주요 LLM 역량의 예를 든다.
- GenAI-1.2.2 (K2) 소프트웨어 테스트에서 GenAI를 사용할 때의 상호작용 모델을 비교한다.

## 1.1 생성형 AI의 기초 및 핵심 개념

생성형 인공지능(GenAI)은 대규모 사전 훈련된 모델을 사용해 텍스트, 이미지, 코드와 같이 사람과 유사한 결과물을 생성하는 인공지능의 한 분야입니다. 거대 언어 모델(LLM)은 대규모 텍스트 데이터셋으로 사전 훈련된 GenAI 모델로, 이를 통해 컨텍스트(정황)를 파악하고 사용자 프롬프트에 따라 관련성 있는 응답을 생성할 수 있습니다.

핵심 개념에는 토큰화(효율적인 처리를 위해 텍스트를 단위로 나누는 것), 컨텍스트 창(관련성을 유지하기 위해 한 번에 고려할 정보의 양을 제한하는 것), 멀티모달 모델(충분한 상호작용을 위해 텍스트, 이미지, 오디오 등 여러 데이터 유형을 처리할 수 있는 모델)이 포함됩니다.

소프트웨어 테스팅에서 이러한 LLM은 인수 조건 검토와 개선, 테스트 케이스나 테스트 스크립트 생성, 잠재적 결함 식별, 결함 패턴 분석, 합성 테스트 데이터 생성이나 전체 테스트 프로세스에 걸친 문서 생성 지원과 같은 작업을 지원할 수 있습니다.

### 1.1.1. AI 스펙트럼: 심볼릭 AI, 고전적 머신 러닝, 딥 러닝 및 생성형 AI

인공지능(AI)은 각기 다른 방식으로 문제를 해결하는 여러 형태의 기술을 포함하는 광범위한 분야이며, 여기에는 심볼릭 AI, 고전적 머신 러닝, 딥 러닝, GenAI 등이 포함됩니다 (여기에는 본 실러버스의 범위를 벗어나는 다른 기술들도 있습니다):

- **심볼릭 AI**는 규칙 기반 시스템을 사용해 인간의 의사 결정을 모방합니다. 기본적으로 심볼릭 AI는 기호와 논리 규칙을 사용해 지식을 표현합니다.
- **고전적 머신 러닝**은 데이터 준비, 피처 선택 및 모델 훈련이 필요한 데이터 기반 접근법으로, 결함 분류와 소프트웨어 문제 예측과 같은 작업에 사용될 수 있습니다.
- **딥 러닝**은 신경망이라는 머신 러닝 구조를 사용해 데이터에서 피처를 자동으로 학습합니다. 딥 러닝 모델은 사용자가 수동으로 피처를 정의할 필요 없이 이미지, 비디오, 오디오, 텍스트와 같은 매우 크고 복잡한 데이터셋에서 패턴을 찾을 수 있지만, 실제로는 데이터 주석, 모델 튜닝, 결과 검증과 같은 작업에 여전히 인간의 개입이 필요할 수 있습니다.
- **생성형 AI**는 딥 러닝 기술을 사용해 훈련 데이터의 패턴을 학습하고 모방함으로써 새로운 콘텐츠(텍스트, 이미지, 코드)를 생성합니다. LLM과 같은 모델은 훈련 범위 내에서 텍스트 생성, 코드 작성, 추론 또는 문제 해결을 시뮬레이션 할 수 있습니다.

요약하면, AI 분야는 각각 다른 강점과 한계를 가지고 다양한 방향으로 발전해 왔습니다. 소프트웨어 테스팅에 GenAI를 사용하는 핵심 이점은 추가적인 훈련 단계 없이 테스트 작업에 직접 적용할 수 있는 사전 훈련 모델을 사용한다는 것이지만, 여기에는 몇 가지 리스크가 따릅니다 (3.1절 참조).

### 1.1.2. 생성형 AI 및 LLM의 기초

생성형 사전 훈련 트랜스포머 딥 러닝 모델을 기반으로 하는 LLM은 서적, 논문, 웹사이트를 포함한 매우 큰 데이터셋으로 훈련됩니다. 소형 언어 모델(SLM)은 거대 언어 모델에 비해 파라미터 수가 적은 모델로, 경량화되고 집중된 GenAI 솔루션을 제공하도록 설계되었습니다. LLM은 언어의 뉘앙스를 처리하고 일관성 있는 콘텐츠를 생성할 수 있습니다.

LLM이 콘텐츠를 처리하고 생성하는 데 도움이 되는 두 가지 핵심 개념은 토큰화와 임베딩입니다. 토큰화와 임베딩은 언어를 모델이 효과적으로 처리할 수 있는 숫자 형태로 변환합니다.

언어 모델에서의

- 토큰화는 텍스트를 토큰이라는 더 작은 단위로 분해하는 과정입니다. 토큰은 문자처럼 작을 수도 있고, 단어의 일부나 단어처럼 클 수도 있습니다. LLM이 문장을 처리할 때, 먼저 입력을 토큰화해 각 토큰을 개별적으로 이해하면서도 전반적인 컨텍스트를 유지할 수 있도록 합니다.
- 임베딩은 토큰의 의미적, 구문적, 문맥적 관계를 생성형 AI 모델이 처리하기에 적합한 형식으로 인코딩하는 숫자 표현입니다. 각 토큰은 고차원 공간의 벡터로 변환되어, 그 의미와 사용법에서 미묘한 정보를 포착합니다. 비슷한 의미나 문맥적 역할을 가진 토큰들은 이 공간에서 서로 가깝게 위치하는 임베딩 속성을 가집니다. 이러한 근접성은 LLM이 단어 관계를 이해하고, 컨텍스트를 유지하며, 일관성 있고 문맥에 맞는 응답을 생성할 수 있게 합니다.

LLM은 트랜스포머 모델로 알려진 신경망 아키텍처를 활용합니다. 트랜스포머 모델은 광범위한 텍스트 시퀀스의 컨텍스트를 처리하고 토큰들이 서로 어떻게 연관되는지 학습하는 등 언어 작업에 뛰어납니다. 추론 중에 LLM은 이러한 학습된 관계를 활용해 시퀀스에서 다음 토큰을 예측하고, 일관성 있고 문맥에 맞는 텍스트를 생성합니다. 트랜스포머 모델은 훈련 데이터와 프롬프트를 기반으로 통계적으로 그럴듯한 새로운 텍스트를 생성하는 데 사용될 수 있습니다. 하지만 그럴듯하다는 것이 반드시 정확하다는 의미는 아닙니다.

LLM은 추론 메커니즘의 확률적 특성과 하이퍼파라미터 설정으로 인해 주로 비결정론적 행동을 보입니다. 이러한 내재된 무작위성은 동일한 입력을 여러 번 제공해도 출력에 변동을 일으킬 수 있습니다.

LLM의 영역에서 컨텍스트 창은 모델이 응답 생성 시 고려할 수 있는 이전 텍스트 양을 토큰 단위로 측정하는 것을 의미합니다. 컨텍스트 창이 클수록 모델은 대규모 테스트 로그를 분석할 때처럼 긴 구절에 걸쳐 일관성을 유지할 수 있습니다. 그러나 컨텍스트 창의 토큰 수를 늘리면 모델이 효과적으로 수행하는 데 필요한 계산 복잡성과 처리 시간도 증가합니다.

실습 목표 HO-1.1.2 (H1): 소프트웨어 테스트 작업에 LLM을 사용할 때의 토큰화와 토큰 수 계산 방식을 실습한다.

이 실습 활동은 교육생들이 토큰화와 LLM 작업 시 필수적인 '토큰화'의 개념과 그 실무적 의미를 이

해할 수 있도록 구성되었습니다. 실습은 크게 두 가지 주요 부분으로 나뉩니다:

- 토큰화: 토큰라이저를 사용해 샘플 텍스트를 개별 토큰으로 분해합니다. 출력물을 검토해 단어, 문장부호, 구절이 어떻게 표현되는지 확인하고 토큰화의 패턴이나 뉘앙스를 찾아냅니다.
- 토큰 수 계산과 분석: 다양한 입력 텍스트에서 생성되는 토큰 수를 측정합니다. 특히 모델이 한 번에 처리할 수 있는 용량인 '컨텍스트 창'의 제한과 효율성 측면을 고려해, 토큰 수가 AI 모델 성능에 어떤 영향을 미치는지 분석합니다.

이 실습을 마치면 교육생들은 다양한 텍스트 구조와 입력 길이가 LLM과의 상호작용에 어떤 영향을 미칠 수 있는지 더 잘 예측할 수 있게 될 것입니다.

### 1.1.3. 파운데이션, 명령어 튜닝, 추론 LLM

거대 언어 모델은 광범위한 작업에서 효과를 높이기 위해 점진적으로 전문화된 훈련 단계를 거쳐 개발됩니다. 이러한 단계를 통해 세 가지 주요 범주인 파운데이션 LLM, 명령어 튜닝 LLM, 추론 LLM이 탄생합니다.

- 파운데이션 LLM: 텍스트, 코드, 이미지 및 기타 다양한 형태의 데이터로 구성된 방대하고 다채로운 데이터셋으로 훈련된 범용 모델입니다. 광범위한 사전 훈련을 통해 자연어 처리, 컴퓨터 비전, 음성 인식과 같은 여러 도메인에 걸쳐 다양한 작업을 수행할 수 있습니다. 강력하고 유연하지만, 특정 작업의 요구사항을 충족하기 위해서는 보통 추가적인 조정 과정이 필요합니다.
- 명령어 튜닝 LLM: 파운데이션 모델에서 파생된 것으로, 프롬프트와 예상 응답을 한 쌍으로 묶은 데이터셋을 사용해 미세 조정(파인 튜닝)을 거치게 됩니다. 이 단계를 통해 인간의 명령어에 대한 정렬(alignment)이 향상되어 실제 애플리케이션에서의 유용성이 개선됩니다. 이 튜닝 과정은 작업 준수, 명령어 이행, 응답 일관성을 최적화해 모델이 사용자의 의도를 효과적으로 해석하고 이에 따라 행동하는 능력을 향상시킵니다.
- 추론 LLM: 추론 모델은 명령어 튜닝 모델을 확장해 논리적 추론, 다단계 문제 해결, 연쇄적 사고(chain-of-thought) 추론과 같은 구조화된 인지 능력을 강조한 모델입니다. 이 모델들은 문맥적 이해, 중간 추론 단계, 복잡한 정보의 종합을 필요로 하는 엄선된 작업을 바탕으로 추가로 훈련되거나 미세 조정을 거칩니다. 결과적으로, 기술 분야를 포함한 고도의 인지적 부하가 요구되는 작업에 더 적합합니다.

소프트웨어 테스트를 위한 GenAI 애플리케이션의 맥락에서는, 명령어 튜닝 LLM(때로는 비추론 LLM이라고도 함)과 추론 LLM이 모두 활용됩니다. 어떤 모델을 선택할지는 당면한 특정 테스트 작업의 복잡성과 추론 요구 수준에 따라 달라집니다.

### 1.1.4. 멀티모달 LLM 과 비전-언어 모델

멀티모달 LLM은 전통적인 트랜스포머 모델을 확장해 텍스트, 이미지, 사운드, 비디오 등 여러 데이터 양

식(modality)을 처리합니다. 이 모델들은 다양한 유형의 데이터 간의 관계를 학습할 수 있도록 크고 다양한 데이터셋으로 훈련됩니다. 다양한 양식을 처리하기 위해 토큰화는 각 데이터 유형에 맞게 조정됩니다. 예를 들어, 이미지는 트랜스포머 모델에서 처리되기 전에 비전-언어 모델을 사용해 임베딩으로 변환됩니다.

비전-언어 모델은 멀티모달 LLM의 하위 집합으로, 시각 정보와 텍스트 정보를 구체적으로 통합해 이미지 캡셔닝(captioning), 시각적 질의응답, 텍스트와 시각적 입력 간의 일관성 분석 등의 작업을 수행합니다.

소프트웨어 테스트에서 멀티모달 LLM, 특히 비전-언어 모델로 강화된 LLM은 큰 기회들을 제공합니다. 이 모델들은 결함 보고서나 사용자 스토리와 같은 텍스트 설명과 더불어, 스크린샷 및 GUI 와이어프레임(화면 설계도) 같은 애플리케이션의 시각적 요소들을 함께 분석할 수 있습니다. 이 기능을 통해 테스터는 예상 결과와 스크린샷의 실제 시각적 요소 간의 불일치를 찾아낼 수 있습니다. 또한, 비전-언어 모델로 강화된 LLM은 텍스트 데이터와 시각적 단서를 모두 통합한 풍부하고 현실적인 테스트 케이스를 생성해 전반적인 커버리지를 높일 수 있습니다.

**실습 목표 HO-1.1.4 (H1): 소프트웨어 테스트 작업을 위해 텍스트와 이미지 입력을 모두 사용하는 멀티모달 LLM 용 프롬프트를 작성하고 실행한다.**

이 실습 활동은 텍스트와 이미지 입력을 모두 사용하는 멀티모달 LLM을 대상으로, 주어진 프롬프트를 작성하고 실행해 소프트웨어 테스트 과제를 다음 두 단계로 해결하는 과정을 포함합니다:

- 입력 검토: 프롬프트와 입력 데이터(텍스트 및 이미지)를 검토합니다.
- 프롬프트 실행 및 실제 결과 검증: 이미지와 텍스트 입력에 멀티모달 LLM을 사용하고 LLM의 응답을 확인합니다.

이 실습은 소프트웨어 테스트 유스 케이스에서 텍스트와 이미지 입력이 모두 들어간 작업에 멀티모달 LLM을 사용하는 방법과 관련된 이점과 잠재적 문제점을 인식하는 방법을 보여줍니다.

## 1.2 소프트웨어 테스트에서 생성형 AI 활용: 핵심 원칙

GenAI는 다양한 테스트 활동에서 혁신적인 역량을 제공합니다. LLMs는 자연어와 코드를 처리하고, 일관성 있는 텍스트와 코드를 생성하며, 질문에 답하고, 정보를 요약하고, 언어를 번역하고, 멀티모달 컨텍스트에서 이미지를 분석하는 데 뛰어난 성능을 발휘합니다.

모든 역할에서 테스트 전문가들은 서로 보완적인 두 가지 방식으로 GenAI를 활용할 수 있습니다. 즉 질문에 즉각적인 응답을 제공하는 GenAI 챗봇을 통한 방식과, 테스트 도구에 통합된 LLM 기반 애플리케이션을 통한 방식입니다.

### 1.2.1. 테스트 작업을 위한 주요 LLM 역량

LLM은 요구사항, 명세, 스크린샷, 코드, 테스트 케이스, 결함 보고서를 해석할 수 있으므로 테스트 프로세스 전반에 걸쳐 필요한 정보를 이해 및 명확히 하고 테스트웨어의 요소들을 생성하는 유용한 도구가 됩니다. 소프트웨어 테스트와 관련된 주요 LLM 역량은 다음과 같습니다:

- 요구사항 분석 및 개선: LLM은 모호하거나 불일치 또는 누락된 정보를 식별해 요구사항 및 기타 테스트 베이스 요소를 분석하는 데 도움을 줄 수 있습니다. 그들은 이해관계자와의 논의 중 요구사항을 명확히 하기 위한 의미 있는 질문을 생성할 수 있습니다.
- 테스트 케이스 생성 지원: LLM은 시스템 요구사항, 사용자 스토리, 기타 테스트 베이스 요소를 기반으로 테스트 케이스를 생성하고 테스트 목표를 제안하는 데 도움을 줄 수 있습니다.
- 테스트 오라클 생성: LLM은 예상 결과를 생성하는 데 도움을 줄 수 있습니다.
- 테스트 데이터 생성: LLM은 데이터셋을 생성하고, 경계값을 설정하며, 다양한 테스트 데이터 조합을 만들 수 있습니다.
- 테스트 자동화 지원: LLM은 테스트 케이스 명세를 기반으로 테스트 스크립트를 생성하고, 수정 사항을 제안하고 적절한 테스트 기법을 식별해 기존 테스트 스크립트를 개선하는 데 도움을 줄 수 있습니다.
- 테스트 결과 분석: LLM은 요약 보고서를 생성하고 심각도 및 우선순위에 따라 이상 사항을 분류해 테스트 결과를 분석하는 데 도움을 줄 수 있습니다.
- 테스트웨어 생성: LLM은 테스트 계획, 테스트 보고서, 결함 보고서 등 다양한 문서를 작성하고 프로젝트가 진행됨에 따라 최신 상태로 유지하는 데 도움을 줄 수 있습니다.

이러한 역량들은 LLM이 전체 테스트 프로세스를 통해 소프트웨어 테스트의 다양한 측면에 어떻게 영향을 미칠 수 있는지를 보여줍니다.

### 1.2.2. 소프트웨어 테스트를 위한 AI 챗봇과 LLM 기반 테스트 애플리케이션

AI 챗봇과 LLM 기반 테스트 애플리케이션은 모두 테스터를 지원할 수 있지만, 기능, 유연성, 통합 접근법에서 차이가 있습니다.

AI 챗봇은 사용하기 쉬운 대화형 인터페이스를 제공해 테스터가 LLM과 직접 소통할 수 있게 합니다. 이러한 자연어 상호작용을 통해 테스터는 질문, 명령어 또는 프롬프트를 입력하고 즉각적이면서도 문맥을 고려한 응답을 받을 수 있습니다. 프롬프트 체이닝(prompt chaining)과 같은 기술을 통해 테스터는 결과물을 반복적으로 다듬을 수 있으며, 이는 챗봇을 일상 작업이나 탐색적 테스트는 물론, 테스트 관련 지식과 실무 노하우를 빠르게 제공할 수 있게 함으로써 신규 테스터의 온보딩(적응)에 특히 효과적인 도구로 만들어 줍니다.

이러한 AI 챗봇은 빠른 피드백, 테스트 개념의 명확화, 요구사항과 잠재적 테스트 케이스의 동적 탐색이

필요한 시나리오에서 특히 유용합니다. 그들의 직관적인 인터페이스는 비기술적인 이해관계자들도 쉽게 접근 가능하게 함으로써, 잠재적 사용자층을 넓히고 더 광범위한 도입을 유도할 수 있습니다.

반면, LLM 기반 테스트 애플리케이션은, 명확하게 정의되고 종종 자동화된 테스트 작업을 수행하기 위해 API를 통해 LLM 기능을 통합하는 방식을 취합니다. 이러한 애플리케이션은 더 높은 맞춤화 가능성과 확장성을 제공하므로, 기업과 도구 공급업체가 기존 테스트 프레임워크에 생성형 AI를 내장할 수 있도록 해줍니다. 이를 통해 테스트 케이스 생성, 결함 분석 또는 테스트 데이터 합성 같은 반복적이거나 복잡한 작업을 자동화할 수 있습니다. 더 나아가서는, 조직이 특정 테스트 역할을 수행하도록 특별히 설계된 AI 에이전트를 만들 수 있습니다 (4장 참조).

테스터가 챗봇을 통해 상호작용하든, 통합된 LLM 기반 애플리케이션을 통해 상호작용하든, LLM 과 상호작용하는 방식에 관계없이 테스트 분야에서 생성형 AI 를 성공적으로 구현하려면 강력한 프롬프트 엔지니어링이 필요합니다(2 장 참조). 정교하게 설계된 프롬프트와 명확하고 구체적인 지침은 LLM 이 테스트 목표에 부합하는 결과물을 생성할 가능성을 극대화하고, 정확성과 관련성을 높이는 데 필수적입니다. 이러한 실천법은 생성형 AI 에서 얻는 가치를 극대화하는 데 도움을 주며, 광범위한 테스트 활동에 대해 더욱 일관되고 신뢰할 수 있는 지원을 가능하게 합니다.

## 제 2 장 효과적인 소프트웨어 테스트를 위한 프롬프트 엔지니어링

365분

### 용어

인수 조건(acceptance criteria), 테스트 스크립트(test script), 테스트 케이스(test case), 테스트 조건(test condition), 테스트 데이터(test data), 테스트 설계(test design), 테스트 보고서(test report)

### 생성형 AI 관련 특정 용어

퓨샷 프롬프팅(few-shot prompting), 메타 프롬프팅(meta prompting), 자연어 처리(natural language processing), 원샷 프롬프팅(one-shot prompting), 프롬프트(prompt), 프롬프트 체이닝(prompt chaining), 프롬프트 엔지니어링(prompt engineering), 시스템 프롬프트(system prompt), 사용자 프롬프트(user prompt), 제로샷 프롬프팅(zero-shot prompting)

## 2장 학습 목표 및 실습 목표:

### 2.1 효과적인 프롬프트 개발

- GenAI-2.1.1 (K2) 소프트웨어 테스트에서 생성형 AI에 사용되는 프롬프트 구조의 예를 든다.
- HO-2.1.1 (H0) 소프트웨어 테스트 작업을 위해 제공된 여러 프롬프트를 관찰하고, 각 프롬프트에서 역할, 컨텍스트, 지시사항, 입력 데이터, 제약조건, 출력 형식 구성 요소를 식별한다.
- GenAI-2.1.2 (K2) 소프트웨어 테스트를 위한 핵심 프롬프팅 기법을 구별한다.
- HO-2.1.2a (H0) 소프트웨어 테스트 작업에 적용된 프롬프트 체이닝, 퓨샷 프롬프팅, 메타 프롬프팅의 데모를 관찰한다.
- HO-2.1.2b (H1) 제공된 예제에 어떤 프롬프트 엔지니어링 기법이 사용되고 있는지 식별한다.
- GenAI-2.1.3 (K2) 시스템 프롬프트와 사용자 프롬프트를 구별한다.

### 2.2 소프트웨어 테스트 작업에 프롬프트 엔지니어링 기법 적용하기

- GenAI-2.2.1 (K3) 테스트 분석 작업에 생성형 AI를 적용한다.
- HO-2.2.1a (H2) GUI 와이어프레임을 기반으로 사용자 스토리에 대한 인수 조건 생성을 위해 멀티모달 프롬프팅을 실습한다.
- HO-2.2.1b (H2) 제공된 사용자 스토리를 점진적으로 분석하고 인수 조건 개선을 위해 프롬프트 체이닝과 인간 검증을 실습한다.
- GenAI-2.2.2 (K3) 테스트 설계와 구현 작업에 생성형 AI를 적용한다.

- HO-2.2.2a (H2) 프롬프트 체이닝, 구조화된 프롬프트, 메타 프롬프팅을 사용해 AI 로 사용자 스토리에서 기능 테스트 케이스 생성을 실습한다.
- HO-2.2.2b (H2) 사용자 스토리에서 Gherkin 스타일 테스트 조건과 테스트 케이스 생성을 위해 퓨샷 프롬프팅 기법을 사용한다.
- HO-2.2.2c (H2) 특정 우선순위와 의존성을 고려해 주어진 테스트 스위트 내에서 테스트 케이스 우선순위를 지정하기 위해 프롬프트 체이닝을 사용한다.
- GenAI-2.2.3 (K3) 자동화된 리그레션 테스트에 생성형 AI 를 적용한다.
- HO-2.2.3a (H2) 키워드 기반 테스트 스크립트를 생성 및 관리하기 위해 퓨샷 프롬프팅을 실습한다.
- HO-2.2.3b (H2) 테스트 보고서 분석을 위한 구조화된 프롬프트 엔지니어링을 실습한다.
- GenAI-2.2.4 (K3) 테스트 모니터링 및 제어 작업에 생성형 AI 를 적용한다.
- HO-2.2.4 (H0) 테스트 데이터로부터 AI 가 준비한 테스트 모니터링 메트릭을 관찰한다.
- GenAI-2.2.5 (K3) 제공된 컨텍스트와 테스트 작업에 적합한 프롬프팅 기법을 선택하고 적용한다.
- HO-2.2.5 (H1) 제공된 테스트 작업의 문맥에 적합한 프롬프팅 기법을 선택하고 적용한다.

### 2.3 생성형 AI 결과 평가 및 소프트웨어 테스트 작업을 위한 프롬프트 개선

- GenAI-2.3.1 (K2) 테스트 작업에 대한 생성형 AI 결과 평가 메트릭을 이해한다.
- HO-2.3.1 (H0) 테스트 작업에서 생성형 AI 결과를 평가하는 데 메트릭이 어떻게 사용될 수 있는지 관찰한다.
- GenAI-2.3.2 (K2) 프롬프트를 평가하고 반복적으로 개선하는 기법의 예를 든다.
- HO-2.3.2 (H1) 제공된 테스트 작업에 대한 프롬프트를 평가하고 최적화한다.

## 2.1 효과적인 프롬프트 개발

효과적인 프롬프트 설계는 GenAI 도구가 소프트웨어 테스트 작업을 정확하고 효율적으로 수행할 가능성을 높여주며, 테스터가 LLM으로부터 유용한 결과를 얻을 수 있도록 합니다. 구조화된 프롬프트는 다양한 구성요소를 포함하며(2.1.1절 참조), 각 구성요소는 LLM에 요구사항과 기대치를 효과적으로 전달하는 프롬프트의 명확성과 정밀성을 높이는 데 기여합니다.

다양한 프롬프트 엔지니어링 기술은 소프트웨어 테스팅에서 프롬프트의 효과를 향상시킵니다. 프롬프트 체이닝, 퓨샷 프롬프팅, 메타 프롬프팅과 같은 기술들은 복잡한 테스팅 과제를 해결하는 데 도움이 됩니다 (2.1.2절 참조).

구조화된 프롬프트(2.1.1절 참조)와 핵심 프롬프팅 기술의 조합은 소프트웨어 테스팅 작업을 위해 LLM에 질의할 때 좋은 결과를 얻는 것을 목표로 합니다 (2.1.3절 참조).

### 2.1.1. 소프트웨어 테스팅에서 생성형 AI를 위한 프롬프트 구조

소프트웨어 테스팅을 위한 구조화된 프롬프트는 일반적으로 다음 여섯 가지 구성요소를 포함합니다:

- **역할(Role):** 역할은 GenAI 모델이 응답을 생성할 때 취해야 할 관점이나 페르소나를 정의합니다. 역할을 명시하면 LLM이 자신의 책임을 결정하고 테스터, 테스트 관리자 또는 테스트 자동화 엔지니어로서 적절한 어조나 접근법을 채택하는 데 도움이 됩니다.
- **컨텍스트(Context):** 컨텍스트는 GenAI 모델이 테스트 조건을 결정하는 데 필요한 배경 정보를 제공합니다. 여기에는 테스트 대상, 테스트할 특정 기능과 관련 문맥 정보에 대한 세부 사항이 포함됩니다.
- **지시사항(Instruction):** 지시사항은 수행할 특정 작업을 개략적으로 설명하며 GenAI에 제공되는 지침입니다. 명확하고, 명령적이며, 간결한 지시사항에는 작업에 대한 설명과 해당 작업에 필요한 모든 관련 요구사항이 포함됩니다.
- **입력 데이터(Input data):** 입력 데이터는 사용자 스토리, 인수 조건, 스크린샷, 코드, 기존 테스트 케이스 또는 출력 예시와 같이 작업을 수행하는 데 필요한 모든 정보를 포함합니다. 상세하고 구조화된 입력 데이터를 제공하면 LLM이 더 정확하고 문맥을 인지하는 결과를 생성하는 데 도움이 됩니다.
- **제약조건(Constraints):** 제약조건은 LLM이 준수해야 할 모든 제한 사항이나 특별 고려 사항을 개요로 설명합니다. 제약조건은 지시사항을 입력 데이터에 어떻게 적용해야 하는지를 명시하는 데 도움이 됩니다.
- **출력 형식(Output format):** 출력 형식은 응답의 예상 형식, 구조 또는 특징을 나타냅니다. 이러한 지표는 LLM의 출력을 형성하는 데 도움이 됩니다.

이러한 구성요소들은 프롬프트의 기본 구조를 형성합니다. 이 구조는 수행할 작업과 사용할 LLM에 따라 프롬프팅 기술의 구현(2.1.2절 참조)과 결합되어야 합니다.

### 실습 목표 HO-2.1.1 (H0): 프롬프트 구성요소 관찰과 분석

시연(데모)에서는 구체적인 소프트웨어 테스트 작업에 맞춤형된 여러 구조화된 프롬프트들을 AI 챗봇에서 실험합니다. 이 프롬프트들은 역할, 컨텍스트, 지시사항, 입력 데이터, 제약조건, 출력 형식의 여섯 가지 주요 구성요소로 이루어진 구조화된 형식을 따릅니다. 이 데모는 이러한 구조화된 프롬프트의 관찰 및 분석을 용이하게 해, 각 구성요소가 소프트웨어 테스트 작업에 사용되는 LLM에 정확하고 관련성 있으며 실행 가능한 통찰력을 제공하는 데 어떻게 기여하는지 강조하는 것을 목표로 합니다.

### 2.1.2. 소프트웨어 테스트를 위한 핵심 프롬프팅 기법

최근 몇 년 동안 다양한 GenAI 사용 사례에 대해 많은 LLM 프롬프팅 기법이 제안되었습니다. 이 중 세 가지 핵심 프롬프팅 기법이 위에서 설명한 여섯 가지 구성요소 프롬프트 구조(2.1.1절 참조)와 함께 GenAI를 사용한 테스트 작업에 일반적으로 사용됩니다: 프롬프트 체이닝, 퓨샷 프롬프팅, 메타 프롬프팅.

- 프롬프트 체이닝(Prompt chaining)은 하나의 작업을 일련의 중간 단계들(여러 개의 프롬프트)로 나누는 방식입니다. 각 단계의 결과는 다음 단계로 진행하기 전에 수동 또는 자동으로 확인되고 개선됩니다. 각 응답이 다음 프롬프트에 영향을 주기 때문에 이 접근법은 더 높은 정확도로 이어집니다. 프롬프트 체이닝은 작업이 복잡하고 하위 작업으로 분해하고 중간 LLM 출력의 체계적인 확인이 필요한 테스트 프로세스에서 특히 유용합니다. 또한 테스트 프로세스에서 역동적인 상호작용을 가능하게 합니다.
- 퓨샷 프롬프팅(Few-shot prompting)은 프롬프트 내에 LLM을 위한 예시들을 제공하는 방식입니다. 제로샷 프롬프팅(예시 없음)이 모델의 기존 지식에 의존해 응답을 생성하는 반면, 원샷 프롬프팅은 주어진 입력에 대해 예상 결과물을 보여주기 위해 하나의 예시를 제공합니다. 퓨샷 프롬프트는 모델의 원하는 응답 행동을 더욱 공고히 하기 위해 두 개 이상(a few)의 예시를 제공합니다.  
이 기법은 모델에 명확한 참조를 제공해 결과를 일관되고 기대에 부응하도록 안내하는 데 도움이 됩니다. 퓨샷 프롬프팅은 예시를 통해 필요한 행동을 설명할 수 있는 작업에 특히 효과적이어서, 모델이 효과적으로 일반화해 신뢰할 수 있는 결과를 생성할 수 있게 합니다.
- 메타 프롬프팅(Meta prompting)은 AI가 자체 프롬프트를 생성하거나 개선하는 능력을 활용합니다. 반복적인 주기 과정에서 LLM은 테스터에 의해 평가되고 개선될 수 있는 프롬프트를 생성할 수 있습니다. 이 접근법은 최적화된 프롬프트에 대한 LLM의 지식을 활용해 프롬프트 품질을 최적화합니다. 메타 프롬프팅은 효과적인 프롬프트를 설계하는 데 필요한 수동 노력을 줄여주므로 효율성과 프롬프트 최적화가 중요한 경우에 특히 유용합니다. 메타 프롬프팅의 또 다른 장점은 테스터가 효과적인 프롬프트를 만드는 방법을 잘 모를 때, LLM과 협력해 공동으로 만들 수 있다는 것입니다. 이는 테스터와 AI가 공유된 목표를 달성하기 위해 상호작용하며 함께 작업하는 GenAI 도구와의 페어링 형태를 반영합니다.

이러한 프롬프팅 기법들은 LLM 결과를 개선하기 위해 효과적으로 조합해 사용할 수 있습니다.

### 실습 목표 HO-2.1.2a (H0): 소프트웨어 테스트 작업에서 프롬프트 체이닝, 퓨샷 프롬프팅, 메타 프롬프팅 관찰과 토론

참가자들은 AI 챗봇에서 각각 구체적인 소프트웨어 테스트 작업에 적용된 프롬프트 체이닝(prompt chaining), 퓨샷 프롬프팅(few-shot prompting), 메타 프롬프팅(meta prompting)을 실험하게 됩니다. 시연은 소프트웨어 테스트 맥락에서 이러한 프롬프팅 기술들을 탐색 및 토론하고, 각 기술이 LLM 결과물의 정확성과 완전성에 어떻게 기여하는지 강조하는 것을 목표로 합니다.

### 실습 목표 HO-2.1.2b (H1): 주어진 예제에서 어떤 프롬프트 엔지니어링 기법이 사용되고 있는지 식별

참가자들은 소프트웨어 테스트와 관련된 일련의 프롬프트 예시들을 읽고 적용된 핵심 프롬프팅 기술을 식별합니다. 중점은 프롬프트 체이닝, 퓨샷 프롬프팅, 메타 프롬프팅과 같은 기술을 인식하는 동시에 이들의 뚜렷한 특징과 실제 적용 사례를 강조하는 데 있습니다. 이 활동은 서로 다른 프롬프팅 기술이 소프트웨어 테스트에서 GenAI의 효과적인 사용을 어떻게 향상시키는지에 대한 참가자들의 이해를 심화시키는 것을 목표로 합니다.

## 2.1.3. 시스템 프롬프트와 사용자 프롬프트

시스템 프롬프트와 사용자 프롬프트는 LLM과의 상호작용에서 서로 다른 목적을 수행하며, 각각 대화를 형성하는 데 뚜렷한 역할을 합니다.

시스템 프롬프트는 일반적으로 개발자나 테스터에 의해 정의되며, LLM의 전반적인 행동을 안내하고 대부분의 인터페이스에서 챗봇 사용자가 보거나 편집할 수 없습니다. 시스템 프롬프트는 LLM의 행동, 성격, 운영 파라미터를 정의하는 사전 정의된 명령어 세트 역할을 합니다. 운영 파라미터는 LLM이 어떻게 응답하는지를 결정합니다 — 예를 들어, 공식적인 톤 사용, 답변을 간결하게 유지, 도메인별 규칙 존중, 특정 행동 회피 등입니다.

시스템 프롬프트는 전체 대화에 대한 규칙을 설정합니다. 역할, 컨텍스트, 제약조건과 같은 구조화된 프롬프트의 일부를 포함할 수 있습니다. 시스템 프롬프트는 상호작용 세션 동안 일정하게 유지되며 LLM이 어떻게 응답해야 하는지에 대한 기본 프레임워크를 설정합니다.

반면, 사용자 프롬프트는 챗봇 사용자의 실제 입력이나 질문을 나타냅니다. 이는 각 상호작용마다 변경되며 챗봇 사용자가 LLM에 처리하길 원하는 특정 지시사항, 질문, 작업을 포함할 수 있습니다. 시스템 프롬프트와 달리 사용자 프롬프트는 직접 볼 수 있으며 각 응답에 대한 즉각적인 컨텍스트를 형성합니다.

일반적인 사용법은 대화 시작 시 시스템 프롬프트를 한 번 설정한 다음, 각 상호작용에 대해 연속적인 사용자 프롬프트를 보내는 것입니다. LLM은 변하지 않는 시스템 프롬프트와 현재의 사용자 프롬프트를 함께 고려해 응답을 생성합니다. 효과적인 구현을 위해 시스템 프롬프트는 LLM의 역할과 가능한 제약조건에 대해 명확하고 구체적이어야 합니다.

사용자 프롬프트는 명시적인 지침과 함께 관련 컨텍스트와 출력 형식에 대한 지침을 포함해 명확하고 체계적이어야 합니다.

## 2.2 소프트웨어 테스트 작업에 프롬프트 엔지니어링 기법 적용하기

소프트웨어 테스트에 프롬프트 엔지니어링 기법을 적용하면, GenAI가 테스트 분석, 테스트 설계, 테스트 자동화, 테스트 케이스 우선순위 지정, 결함 탐지, 커버리지 분석, 테스트 모니터링과 제어와 같은 테스트 작업을 지원할 수 있게 됩니다. 프롬프트 체이닝, 퓨샷 프롬프팅, 메타 프롬프팅과 같은 기법을 사용하고 결합함으로써, 팀은 특정 테스트 목표에 맞게 AI 프롬프트를 조정해 결과물을 더 정밀하고, 관련성 있으며, 효과적으로 만들 수 있습니다. 의미 있는 GenAI 결과물을 얻기 위해서는 고품질의 입력이 필수입니다.

### 2.2.1. 생성형 AI를 활용한 테스트 분석

GenAI는 테스트 조건을 생성 및 우선순위화하고, 테스트 베이스의 결함을 식별하며, 커버리지 분석을 제공함으로써 테스트 분석 작업을 지원할 수 있습니다. 입력 데이터에는 요구사항, 사용자 스토리, 기술 명세, GUI 와이어프레임 및 기타 관련 정보가 포함됩니다. 출력물은 우선순위가 지정된 테스트 조건(예: 인수 조건)과 같은 일반적인 테스트 분석 산출물로 구성됩니다.

GenAI가 지원할 수 있는 대표적인 테스트 분석 작업은 다음과 같습니다:

- **테스트 베이스에서 잠재적 결함 식별:** GenAI는 테스트 베이스를 분석해 결함으로 이어질 수 있는 불일치, 모호성, 불완전한 정보를 식별하는 데 도움을 줄 수 있습니다. LLM은 유사한 요구사항 패턴을 비교하거나 이전 결함 보고서 내용을 적용함으로써 잠재적인 이상 징후를 표시하고 개선 사항을 제안할 수 있습니다.
- **테스트 베이스 기반 테스트 조건 생성:** LLM은 요구사항과 사용자 스토리를 분석해 테스트 조건을 생성할 수 있습니다. 자연어 처리를 사용해 요구사항 의미를 해석하고 측정할 수 있는 테스트 가능한 문장으로 분해할 수 있습니다. 이는 요구사항을 특정 테스트 조건으로 변환하는 데 도움이 될 수 있습니다.
- **리스크 레벨 기반 테스트 조건 우선순위 지정:** LLM은 각 테스트 조건의 실패 가능성과 영향에 대한 정보를 바탕으로, 테스트 노력을 우선순위화 하는 데 도움을 줄 수 있습니다. LLM은 규제 준수, 사용자 대면 기능(예: 로그인 기능이나 결제 처리) 및 과거 결함 데이터와 같은 측면을 고려해 우선순위를 제안할 수 있습니다.
- **커버리지 분석 지원:** LLM은 요구사항과 사용자 스토리를 테스트 조건에 매핑함으로써 커버리지 분석을 수행해 테스트 베이스의 모든 측면이 커버되었는지 확인할 수 있습니다. 이는 복잡한 요구사항을 가진 프로젝트에서 특히 유용하며, 커버리지의 격차는 누락된 결함으로 이어질 수 있습니다.

- **테스트 기법 제안:** GenAI는 테스트 중인 요구사항이나 사용자 스토리 유형에 따라 관련 테스트 기법(예: 경계값 분석, 동등 분할)을 제안할 수 있습니다. 이는 테스터가 특정 테스트 컨디션에 대해 가장 효과적인 테스트 기법을 적용하는 데 도움이 될 수 있습니다.

수행할 작업 관련 LLM에 제공되는 입력의 품질과 연관성은 LLM이 생성하는 출력의 정확성과 정밀도에 직접적인 영향을 미칩니다.

**실습 목표 2.2.1a (H2): GUI 와이어프레임 기반 사용자 스토리에 대한 인수 조건을 생성하기 위해 구조화된 멀티모달 프롬프트 작성을 실습**

이는 멀티모달 입력(텍스트와 이미지)을 사용해 구조화된 프롬프트를 작성하는 실습입니다. 사용자 스토리와 GUI 와이어프레임으로부터 고품질(즉, 잘 구성되고, 명확하며, 완전한)의 인수 조건을 생성하는 것이 목표입니다. 입력 필드에 대한 제약조건이나 데이터 처리에 적용될 비즈니스 규칙 등의 컨텍스트를 제공하기 위해 다른 텍스트 요소를 추가할 수 있습니다.

LLM에서 얻은 결과는 테스트 분석 작업을 위해 구조화된 프롬프트(역할, 컨텍스트, 지시사항, 텍스트와 이미지 입력 데이터, 제약조건, 출력 형식)의 다른 공식화가 미치는 영향을 평가하기 위해 비교됩니다.

이 실습은 프롬프트 구조화의 중요성, 정확한 지시사항의 기여, LLM으로부터 정확하고 연관성 있는 결과를 얻는 데 있어 텍스트와 이미지 문맥 데이터의 중요성에 대한 실제 경험을 제공합니다.

**실습 목표 2.2.1b (H2): 주어진 사용자 스토리를 점진적으로 분석하고 인수 조건을 개선하기 위해 프롬프트 체이닝과 인간 검증 실습**

이는 주어진 사용자 스토리를 분석하고 인수 조건을 개선하기 위해 프롬프트 체이닝을 실습하는 것입니다. 먼저 모호성을 식별하고, 그 다음 테스트 가능성을 평가하고, 마지막으로 완전성을 평가합니다. 이 실습은 단계별 접근을 장려하며, 각 테스트 목표를 달성하기 위해 인수 조건이 잘 구성되고 실행 가능한지 확인하며 각 단계마다 분석을 개선해 나갑니다. 각 단계에서 LLM이 제공한 결과는 필요에 따라 수동으로 검증하고 수정하는데, 이때 결과물을 직접 조정하거나 LLM과의 프롬프트 체이닝 프로세스를 거칩니다. 이런 방식을 통해, 다음 단계에서는 이전 단계에서 도출된 정제된 결과물을 사용해 인수 조건을 개선하는 또 다른 측면을 다루게 됩니다.

이 실습은 복잡한 작업을 하위 작업으로 나누고 각 단계의 결과를 인간이 검증하는 것의 이점에 대한 실제 경험을 제공합니다.

## 2.2.2. 생성형 AI를 활용한 테스트 설계 및 구현

[ISTQB\_CTFL\_SYL]에 설명된 바와 같이, 테스트 설계는 테스트 조건을 정교화하고 다듬는 과정을 포함하며, 이는 이후 테스트 케이스 및 기타 테스트웨어로 변환됩니다. 테스트 구현은 테스트를 수행하는 데 필요한 테스트웨어를 생성하거나 획득하는 과정을 수반합니다.

수동 테스트와 자동화된 테스트 스크립트 모두 GenAI의 지원을 받아 생성되고, 우선순위가 지정되며, 테스트 실행 일정 내에 배치될 수 있습니다. GenAI는 테스트 케이스, 테스트 데이터, 테스트 스크립트, 테스트 환경 등 다양한 테스트웨어의 생성과 평가를 지원함으로써 이 대규모 테스트 활동 그룹을 크게 지원할 수 있습니다.

GenAI가 지원할 수 있는 대표적인 테스트 설계와 구현 작업은 다음과 같습니다:

- **테스트 케이스 생성:** 자연어 처리를 통해 GenAI는 기능 및 비기능 요구사항을 기반으로 테스트 케이스 초안을 생성할 수 있습니다. 적절한 정보로 프롬프트를 받으면 LLM은 테스트 사전 조건과 입력, 예상 결과, 커버리지 기준을 제안해 기본적인 기능 검증부터 복잡한 엔드투엔드 테스트에 이르기까지 다양한 테스트 목표를 충족하는 테스트 케이스를 생성할 수 있습니다.
- **테스트 데이터 합성:** GenAI는 운영 데이터와 유사하며 데이터 프라이버시를 보호하는 대표적인 합성 테스트 데이터를 생성해 극단적인 상황과 다양한 테스트 조건을 커버할 수 있습니다. 이 합성 테스트 데이터는 기능과 비기능 테스트에 사용될 수 있습니다. AI가 생성한 테스트 데이터는 애플리케이션 요구사항에 맞춰 조정될 수 있으며, 민감한 정보를 노출하지 않고 현실적인 시나리오를 시뮬레이션 할 수 있습니다.
- **자동화된 테스트 스크립트 생성:** GenAI는 구조화된 테스트 케이스로부터 수동 테스트 절차와 자동화된 테스트 스크립트를 생성하고 테스트 단계를 해석해 다양한 테스트 자동화 프레임워크와 호환되는 코드로 변환할 수 있습니다. 이러한 테스트 스크립트는 새로운 요구사항에 따라 업데이트되거나 확장될 수 있습니다.
- **테스트 실행 일정 수립과 우선순위 지정:** GenAI는 테스트 케이스와 그 상호 의존성을 분석해 우선순위, 관련 리스크, 자원 가용성, 테스트 목표에 따라 테스트 실행 스케줄을 최적화할 수 있습니다.

### 실습 목표 2.2.2a (H2): 프롬프트 체이닝, 구조화된 프롬프트, 메타 프롬프팅을 사용해 AI로 사용자 스토리에서 기능 테스트 케이스 생성을 실습

이 실습은 철저한 커버리지를 확보하기 위해 GenAI를 사용해 사용자 스토리에서 기능 테스트 케이스를 개발하는 데 중점을 두며, 프롬프트 체이닝, 구조화된 프롬프트, 메타 프롬프팅 기법을 사용합니다. 첫 번째 단계는 주어진 인수 조건을 기반으로 특정 출력 형식에 따라 기능 테스트 케이스를 생성하도록 AI에 지시하는 프롬프트를 만드는 것입니다. 두 번째 단계는 생성된 테스트 케이스의 완전성을 검증하는 것입니다. 여기서 프롬프트는 AI가 커버리지를 요약하는 표를 생성하게 함으로써 각 인수 조건이 누락 없이 다루어졌는지 확인합니다. 마지막으로, 세 번째 단계는 엔드투엔드 테스트 절차 생성

을 돕기 위한 메타 프롬프트를 만드는 것입니다. 이 메타 프롬프트는 포괄적인 엔드투엔드 테스트를 생성하도록 프롬프트를 개선하는 데 도움을 주며, 효과를 극대화하기 위한 반복적인 개선을 유도합니다.

이 실습은 테스트 케이스 생성, 커버리지 검증, 엔드투엔드 테스트를 위해 LLM을 사용하는 것에 대한 이해를 향상시킵니다.

### 실습 목표 2.2.2b (H2): 사용자 스토리에서 Gherkin 스타일 테스트 조건과 테스트 케이스를 생성하기 위해 퓨샷 프롬프팅 기법을 사용

이 실습은 주어진 사용자 스토리에서 퓨샷 프롬프팅을 사용해 Gherkin 스타일 테스트 케이스를 생성하는 방법에 관한 것입니다. 사전 정의된 예제와 Gherkin 구문을 검토하는 것을 시작으로, 1단계는 프롬프트에 포함할 n개의 예제를 선택하는 것입니다. 각 예제는 예상되는 결과를 모델링하기 위한 사용자 스토리, 테스트 조건, 'given-when-then' 형식의 테스트 케이스가 포함되어야 합니다. 그 다음 이 프롬프트는 새로운 사용자 스토리에 적용되어 원래의 테스트 조건을 반영하는 Gherkin 시나리오를 생성합니다. 결과가 부정확하면 프롬프트나 예제를 개선해야 합니다.

이 실습은 현실적인 테스트 설계와 구현 작업에 퓨샷 프롬프팅 기법을 적용하는 경험을 얻는 데 도움이 됩니다.

### 실습 목표 2.2.2c (H2): 특정 우선순위와 의존성을 고려해 제공된 테스트 스위트 내에서 테스트 케이스의 우선순위를 지정하기 위해 프롬프트 체이닝을 사용

이 실습은 GenAI를 사용해 주어진 테스트 스위트 내에서 테스트 케이스 우선순위를 개선하는 데 중점을 두며, 관련 리스크 분석 및 테스트 케이스 간의 의존성을 고려합니다. 세션은 리스크 기반, 커버리지 기반, 요구사항 기반과 같은 다양한 테스트 접근법에 대한 간략한 개요와 주어진 테스트 스위트 검토로 시작합니다. 참가자들은 다양한 테스트 우선순위 전략에 대한 실행 가능한 우선순위 계획을 세우기 위해 프롬프트 제작에 참여하게 됩니다. 프롬프트와 주어진 입력 데이터를 기반으로 한 LLM의 결과는 LLM의 추론에서 오류를 감지하기 위해 수동으로 확인되어야 합니다.

이 실습의 목표는 다중 기준 추론 능력(여기서는 테스트 케이스 우선순위를 위해 고려해야 할 다양한 리스크와 의존성)을 요구하는 테스트 작업에 대해 GenAI를 실험하는 것입니다.

## 2.2.3. 생성형 AI를 활용한 자동화된 리그레션 테스트

새로운 반복주기(iteration)나 릴리스가 완료될 때마다 수행해야 할 리그레션 테스트 케이스의 수는 증가하는 경우가 많습니다. 이러한 특성 때문에 리그레션 테스트는 자동화하기에 매우 이상적이며, 특히

CI/CD 파이프라인에서는 테스트 실행 빈도가 높아 자동화의 이점이 더욱 크게 나타납니다. GenAI는 자동화된 리그레션 테스트 스위트의 생성, 유지보수, 최적화를 지원해 이 과정을 간소화할 수 있습니다. GenAI는 코드베이스 변경에 동적으로 적응하고 영향 분석을 수행함으로써, 최근 수정 사항에 의해 가장 영향을 받을 가능성이 높은 소프트웨어 영역을 찾아내 리그레션 테스트 노력을 가장 필요한 곳에 집중시킬 수 있습니다.

GenAI 프롬프팅이 지원할 수 있는 대표적인 자동화된 리그레션 테스트와 테스트 보고 활동은 다음과 같습니다:

- **키워드 기반 자동화를 통한 자동화된 테스트 스크립트 구현:** LLM은 사전 정의된 키워드가 공통 테스트 단계를 나타내는 키워드 기반 테스트 자동화 프레임워크를 기반으로 테스트 스크립트를 구현하는 데 사용될 수 있습니다. GenAI는 이런 키워드를 특정 테스트 케이스에 매핑하고, 테스트 스크립트를 생성하며, 테스터와 테스트 자동화 엔지니어의 작업을 지원할 수 있습니다.
- **영향 분석과 테스트 최적화:** GenAI는 코드 변경 사항을 분석해 고위험 영역을 식별하고, 이를 통해 가장 필요한 부분에 목표 지향적인 리그레션 테스트를 가능하게 하는 데 사용될 수 있습니다.
- **자가 치유와 적응형 테스트:** GenAI는 사소한 UI 또는 API 변경을 처리하기 위해 테스트 스크립트를 자동으로 조정해, 작은 수정으로 인한 불필요한 실패를 방지하고 테스트 스위트가 시간이 지나도 안정적으로 유지되도록 하는 데 사용될 수 있습니다.
- **자동화된 테스트 보고와 인사이트:** GenAI는 성공 지표, 실패, 주요 인사이트가 포함된 상세하고 시기적절한 테스트 보고서 생성을 가능하게 함으로써 이해관계자에게 테스트 동향을 강조하고 잠재적인 실패 지점에 대한 예측적 인사이트를 제공하는 대시보드를 제공합니다.
- **향상된 결함 보고와 근본 원인 분석:** GenAI는 테스트 로그, 스크린샷, 테스트 환경 데이터를 포함하는 포괄적인 결함 보고서를 자동으로 취합하도록 지원할 수 있습니다.

이러한 활동은 기능과 비기능 리그레션 테스트를 포함한 다양한 리그레션 테스트에 적용될 수 있습니다. 그러나 테스터는 GenAI가 실수를 할 수 있음을 인지해야 합니다. 따라서 생성된 출력은 관련 리스크에 맞춰 신중하게 검증해야 합니다 (3장 참조).

또한, GenAI는 각각 고유한 과제와 해결책을 가진 엔드투엔드 GUI 및 API 기반 자동화 리그레션 테스트를 지원할 수 있습니다. GUI 테스트는 사용자 인터페이스의 빈번한 변경 때문에 자주 불안정해집니다. GenAI는 동적 로케이터와 수정된 상호작용과 같은 변경 사항을 처리하기 위해 테스트 스크립트를 자동으로 조정해 수동 개입의 필요성을 줄일 수 있습니다. API 리그레션 테스트는 변경되는 요청/응답 형식, 엔드포인트와 인증 등의 과제에 직면합니다. GenAI는 변화하는 API 명세에 맞춰 테스트 스크립트를 자동으로 조정하고 다양한 테스트 데이터를 생성해 포괄적인 커버리지를 유지하고 수동 업데이트의 필요성을 줄일 수 있습니다.

**실습 목표 2.2.3a (H2): 키워드 기반 테스트 스크립트를 생성 및 관리하기 위해 플샷 프롬프팅을 실습**

이 실습은 GUI 테스트 자동화 프레임워크를 사용해 주어진 웹 애플리케이션에 대한 테스트 스크립트를 개발하고 자동화하는 데 중점을 둡니다. 실습은 테스트 자동화와 테스트 스크립트 디버깅의 두 가지 주요 섹션으로 구성됩니다. 실습의 첫 부분은 키워드 라이브러리에 대한 문서 작성, 초기 테스트 스크립트 생성, AI를 통한 이러한 테스트 스크립트의 검증, 그리고 추가 테스트 스크립트를 통한 커버리지 확장에 대한 지침을 제공합니다. 두 번째 부분은 시스템 프롬프트를 사용해 테스트 스크립트를 확인하고 수정할 수 있는 AI 조수를 만들어 디버깅 지원에 중점을 둡니다.

이 실습은 전통적인 테스트 자동화와 AI 지원 검증을 결합해, 플샷 프롬프팅이 키워드 기반 테스트 스크립트를 생성, 유지보수, 디버깅하는 데 효과적으로 사용할 수 있는 방법을 보여줍니다.

#### **실습 목표 2.2.3b (H2): 리그레션 테스팅에서 테스트 보고서 분석을 위한 구조화된 프롬프트 작성**

이 실습은 구조화된 프롬프트를 활용해 리그레션 테스트 보고서를 분석하는 체계적인 접근법을 보여줍니다. 프로세스는 제공된 테스트 결과 분석과 테스트 명세와의 비교로 시작됩니다. 그런 다음 유사한 결함의 클러스터링, 알려진 이상사항 목록 유지보수, 그리고 발견 사항의 교차 확인으로 진행됩니다. 각 단계는 단일 LLM 대화에서 다음 단계와 연결됩니다.

이 단계별 접근법은 구조화된 프롬프트가 리그레션 테스트 결과와 테스트 로그를 실행 가능한 통찰력으로 변환해 리그레션 테스팅의 맥락에서 효과적인 테스트 보고서 분석을 지원하는 방법을 보여줍니다.

### **2.2.4. 생성형 AI를 활용한 테스트 모니터링과 제어**

테스트 모니터링 작업은 대량의 (때로는 비정형적인) 데이터 검색을 포함하며, 이는 종종 GenAI가 분석하고 종합하는 데 도움을 줄 수 있는 테스트 관리 도구에 이미 존재합니다.

GenAI는 다음과 같은 다양한 테스트 모니터링과 제어 작업을 용이하게 합니다:

- **테스트 모니터링과 메트릭 분석:** GenAI는 테스트 모니터링의 자동화를 촉진하고, 동향을 분석해 잠재적 리스크를 예측하며, 계획에서 벗어난 모든 편차에 대해 팀에 경고할 수 있습니다. 이를 통해 팀은 정보와 품질 표준을 유지하기 위한 조치를 취할 수 있습니다.
- **테스트 제어:** GenAI는 필요에 따라 테스트 우선순위를 재조정하고, 테스트 스케줄을 조정하며, 자원을 재할당하기 위한 인사이트를 제공해 테스트 제어를 지원할 수 있습니다. 이는 테스팅을 유연하게 유지하고 우선순위가 높은 영역에 집중할 수 있도록 합니다.
- **테스트 완료 인사이트와 지속적인 학습:** GenAI는 성공 사례와 교훈을 강조하는 테스트 완료 보고서 생성을 지원할 수 있습니다. 이를 통해 팀은 테스트 전략을 개선하고 미래의 테스트 프로세스를 향상시킬 수 있습니다.

- **향상된 테스트 메트릭 시각화 및 보고:** GenAI는 동적 대시보드와 자연어 요약 생성을 지원해 모든 이해관계자가 관련 메트릭에 접근할 수 있도록 보장할 수 있습니다. 이 지원은 빠른 결정을 내리는 데 필요한 정보를 제공하고 테스트 진행 상황에 대한 명확한 시각을 제공합니다.

#### 실습 목표 2.2.4 (H0): 테스트 데이터로부터 AI가 준비한 테스트 모니터링 메트릭을 관찰

이 시연은 GenAI가 테스트 데이터를 실행 가능한 테스트 모니터링 메트릭으로 변환해 테스트팀이 정보에 입각한 의사 결정을 내리는 데 어떻게 도움을 주는지 보여줍니다. 테스트 도구에서 추출한 테스트 데이터를 시작으로, LLM은 이를 처리해 테스트 진행 상황, 결함 동향나 커버리지와 같은 주요 메트릭을 생성하고 잠재적 리스크를 강조합니다. 이렇게 AI가 생성한 메트릭은 대시보드에 표시되고 모든 이해관계자가 쉽게 이해할 수 있도록 자연어로 요약될 수 있습니다.

이 시연은 GenAI가 테스트 데이터를 실용적인 통찰력으로 전환해 테스트팀이 테스트 진행 상황을 모니터링하고, 품질을 관리하며, 변화에 신속하게 적응하는 데 어떻게 도움이 되는지를 보여줍니다.

### 2.2.5. 소프트웨어 테스트를 위한 프롬프팅 기법 선택

다음 표는 2.1.2절에서 언급된 세 가지 프롬프팅 기법이 테스트 작업의 특성에 따라 얼마나 적합한지를 보여줍니다.

| 프롬프팅 기법  | 권장 사용 사례                            | 주요 특징 및 적용                                                                                                           |
|----------|-------------------------------------|----------------------------------------------------------------------------------------------------------------------|
| 프롬프트 체이닝 | 각 단계에서 인간의 검증이 필요한 정밀성을 요구하는 복잡한 작업 | 작업을 더 작은 단계로 나누며, 각 테스트 단계의 기능 정확성을 확인하는 테스트 분석, 테스트 설계, 테스트 자동화에 유용합니다.                                             |
| 퓨샷 프롬프팅  | 반복적이거나 특정/제한된 출력 형식의 작업             | 반복적인 생성을 수행하기 위해, Gherkin 형식 테스트 케이스(예: 시나리오 기반), 키워드 기반 테스트 또는 특정 출력 형식의 테스트 보고서 작성과 같은 특정 패턴을 가진 예시를 GenAI에 제공합니다. |
| 메타 프롬프팅  | 유연하고 동적인 작업, 새로운 작업을 위한 프롬프트 작성에 유용 | 수행할 목표와 작업에 대한 일반적인 설명을 제공해, LLM이 프롬프트를 생성하도록 안내합니다. 테스트 보고서 분석과 이상 탐지와 같은 모든 종류의 복잡한 작업에 유용합니다.                     |

작업 하나에 여러 기법을 사용하는 것도 가능합니다. 예를 들어, 메타 프롬프팅을 사용해 초기 프롬프트를 만들 수 있습니다. 이 생성된 프롬프트에는 조정이 필요하고 강화될 수 있는 예시가 포함될 수 있습니다 (퓨샷 프롬프팅). 마지막으로, 중간 단계의 검증을 가능하게 하기 위해 작업을 더 작은 하위 작업으로 나누는 것이 유용할 수 있습니다 (프롬프트 체이닝).

### 실습 목표 2.2.5 (H1): 주어진 테스트 작업에 대해 문맥에 적합한 프롬프팅 기법 선택

이 실습은 다양한 테스트 작업에 적합한 프롬프팅 기법을 선택하는 데 중점을 둡니다. 참가자들은 다양한 과제가 있는 여러 테스트 과제를 받습니다. 각 테스트 작업에 대해 참가자들은 작업의 성격(정밀성이 필요한지, 반복적인 구조가 필요한지)을 평가하고 문맥에 가장 잘 맞고 작업의 특정 요구를 충족하는 프롬프팅 기법을 제안해야 합니다. 선택 사항은 그룹에서 논의됩니다.

이 실습은 다양한 프롬프팅 기법이 실제 테스트 노력에서 효과적으로 사용될 수 있는 방법에 대한 이해를 심화시키기 위해 설계되었습니다.

## 2.3 생성형 AI 결과 평가와 소프트웨어 테스트 작업을 위한 프롬프트 개선

소프트웨어 테스트에서 GenAI의 성능을 평가하려면 생성된 결과물의 품질, 관련성, 효과성을 평가하기 위한 명확한 메트릭 세트가 필요합니다. 이러한 메트릭은 일반적인 특정 작업에 특화되어 있는 상관 없이, LLM 프롬프팅을 최적화하는 데 도움이 됩니다.

### 2.3.1. 테스트 작업에 대한 생성형 AI 결과 평가 메트릭

테스트 작업에 대한 GenAI 결과의 품질과 효율성을 평가하는 데 여러 메트릭을 사용할 수 있습니다:

| 메트릭                | 설명                                                     | 예시                                                 |
|--------------------|--------------------------------------------------------|----------------------------------------------------|
| 정확성<br>(Accuracy)  | 생성된 결과물이 전문가가 작성한 테스트 케이스, 요구사항, 기타 표준 대비 전반적인 정확도를 측정 | 생성된 테스트 케이스가 명시된 모든 요구사항을 다루는 비율                   |
| 정밀도<br>(Precision) | 생성된 결과물이 특정 목표에 대해 얼마나 정확한지를 평가                        | 생성된 테스트 케이스가 이상 현상을 정확하게 식별하는 비율                   |
| 재현율 (Recall)       | 모델이 데이터셋 내의 모든 관련 인스턴스를 식별하는 능력을 측정                    | 데이터 클래스의 유효/비유효 동등분할을 생성된 테스트 케이스가 다루는 비율          |
| 관련성 및 문맥<br>적합성    | 생성된 결과물이 주어진 문맥에 적용 가능하고 적절한지를 결정                      | 생성된 테스트 케이스가 테스트 베이스와 일관성을 유지하고 도메인별 요구사항을 통합하는 수준 |
| 다양성<br>(Diversity) | 광범위한 입력값과 시나리오가 확실히 다루어지도록 해 중복을 방지                    | 다양한 사용자 행동과 엣지 케이스를 생성된 테스트 케이스가 탐색하는 범위           |

|                                    |                                                              |                                                               |
|------------------------------------|--------------------------------------------------------------|---------------------------------------------------------------|
| 실행 성공률<br>(Execution Success Rate) | 생성된 테스트 산출물 중에서 테스트 환경에서 별도의 수정 없이 즉시 실행 가능한 테스트 산출물의 비율을 측정 | 생성된 테스트 스크립트 중 몇 개가 테스트 환경에서 구문 오류나 출력 형식의 문제없이 실행될 수 있는지의 비율 |
| 시간 효율성<br>(Time Efficiency)        | 수동 테스트 노력에 비해 절약된 시간을 평가                                     | 사람이 동일한 테스트를 작성하는 데 걸리는 시간과 AI가 테스트 케이스를 생성하는 데 필요한 시간을 비교    |

이러한 일반적인 메트릭 외에도, GenAI가 특정 테스트 활동을 얼마나 잘 지원하는지 평가하기 위해 작업별 메트릭을 맞춤화할 수 있습니다.

이러한 메트릭을 효과적으로 평가하기 위해 테스터는 수동 검토를 수행하거나, LLM 출력을 사전 정의된 참조와 비교해 자동화할 수 있습니다. GenAI의 비결정론적 특성을 감안할 때, 메트릭은 통계적으로 유의미한 데이터를 기반으로 해야 합니다.

#### 실습 목표 2.3.1 (H0): 테스트 작업에서 생성형 AI 결과물 평가를 위해 메트릭의 활용성 관찰

주어진 테스트 작업에 대한 시연 중에, GenAI 결과를 평가하기 위한 작업별 메트릭과 해당 테스트 작업에서 LLM으로 얻은 결과에 대한 구체적인 적용을 볼 수 있습니다.

이 시연은 소프트웨어 테스트에 활용되는 생성형 AI의 결과에 대한 신뢰를 확보하는 데 있어 평가 메트릭이 얼마나 중요한지를 보여줍니다.

### 2.3.2. 프롬프트 평가와 반복적 개선 기법

위에서 제시된 메트릭을 바탕으로, AI 결과를 개선하기 위해 프롬프트 평가와 개선을 위한 구체적인 기법이 사용됩니다:

- **반복적인 프롬프트 수정:** 기본 프롬프트로 시작해 실제 결과에 따라 반복적으로 수정하며, 점진적으로 더 많은 컨텍스트를 추가하거나 표현을 조정(예. 전문 용어 관련)해 구체성과 관련성을 향상시킵니다.
- **프롬프트 A/B 테스트:** 여러 버전의 프롬프트를 만들고, 사전 정의된 메트릭을 기반으로 어떤 버전이 더 나은 결과를 생성하는지 평가합니다. 이 접근법은 어떤 프롬프트 문구나 구조가 가장 정확하고 관련성 있는 결과를 생성하는지 결정하는 데 도움이 됩니다.
- **출력 결과 분석:** AI가 생성한 결과물에서 부정확성이나 불일치(예: 테스트 베이스와의 비교 등)를 검토합니다. 오류 및 불일치 유형을 이해하면 향후 반복에서 유사한 결함을 피하기 위해 프롬프트를 개선하는 데 도움이 될 수 있습니다.
- **사용자 피드백 통합:** 생성된 결과물의 유용성과 명확성(예: 생성된 테스트의 상세화 수준 등)에 대해 테스터로부터 입력을 수집합니다. 그들의 통찰력을 분석하고 실제 테스트 요구를 더 잘 충

족시킴을 위해 프롬프트를 개선하는 데 사용합니다.

- **프롬프트 길이 및 구체성 조정:** 다양한 프롬프트 길이와 상세화 수준을 실험합니다. 때로는 더 많은 컨텍스트를 추가하면 응답의 품질이 향상될 수 있습니다. 반면에 더 짧은 프롬프트가 더 나은 일반화 결과를 낳을 수도 있습니다.

이러한 기법을 사용해 테스트팀은 GenAI 프롬프트의 지속적인 개선을 보장하기 위해 프롬프트 평가와 최적화 세션을 구성할 수 있습니다. 테스트팀이나 조직 전체에 걸쳐 실천법을 공유하는 것은 프롬프트 기법을 표준화하고 일관된 품질을 유지하는 데 도움이 될 뿐만 아니라, 학습과 반복적 개선의 문화를 촉진합니다. 이러한 협업 접근법은 테스트팀이 집단 지성을 활용하고, 반복되는 오류를 피하며, 프롬프트 라이브러리 공유와 같이 GenAI 도구 활용법을 시간이 지남에 따라 더 효과적으로 개선할 수 있도록 함으로써 GenAI 테스트 방법론의 발전에 기여합니다.

#### **실습 목표 2.3.2 (H1): 주어진 테스트 작업에 대한 프롬프트 평가와 최적화**

이 실습은 주어진 테스트 작업에 프롬프트 최적화 기법을 적용하는 데 중점을 둡니다. 참가자들은 초기 프롬프트로 시작해 AI 생성 결과를 개선하기 위해 반복적으로 다듬어 나갑니다. A/B 테스트와 인간 검증과 같은 기법을 사용해 프롬프트의 품질을 평가하고 개선합니다. 참가자들이 반복적인 개선이 더 효과적이고 문맥에 맞는 테스트 케이스 생성으로 이어진다는 것을 경험하는 것이 목표입니다.

실습이 끝날 때까지 참가자들은 프롬프트 개선의 여러 반복을 수행하고 AI 출력 품질을 개선하기 위해 논의된 메트릭을 사용해 각 반복을 평가합니다.

## 제 3 장 소프트웨어 테스트에서 생성형 AI의 리스크 관리

160분

### 용어

보안(security), 취약점(vulnerability), 데이터 프라이버시(data privacy)

### 생성형 AI 관련 특정 용어

환각(hallucination), 온도(temperature), 추론 오류(reasoning error), 편향(bias), 컨텍스트 조작(context manipulation)

### 3장 학습 목표 및 실습 목표:

#### 3.1 환각, 추론 오류, 편향

- GenAI-3.1.1 (K1) 생성형 AI 시스템에서 환각, 추론 오류, 편향의 정의를 상기한다.
- GenAI-3.1.2 (K3) LLM 출력에서 환각, 추론 오류, 편향을 식별한다.
- HO-3.1.2a (H1) GenAI 를 이용한 테스트에서 환각을 실험한다.
- HO-3.1.2b (H1) GenAI 를 이용한 테스트에서 추론 오류를 실험한다.
- GenAI-3.1.3 (K2) 소프트웨어 테스트 작업에서 GenAI 환각, 추론 오류, 편향에 대한 완화 기법을 요약한다.
- GenAI-3.1.4 (K1) LLM 의 비결정론적 행동에 대한 완화 기법을 상기한다.

#### 3.2 소프트웨어 테스트에서 생성형 AI 의 데이터 프라이버시 및 보안 리스크

- GenAI-3.2.1 (K2) 소프트웨어 테스트에서의 생성형 AI 사용 관련 주요 데이터 프라이버시 및 보안 리스크를 설명한다.
- GenAI-3.2.2 (K2) 소프트웨어 테스트에서 생성형 AI 를 사용할 때의 데이터 프라이버시와 취약점의 예시를 든다.
- GenAI-3.2.3 (K2) 소프트웨어 테스트에서 생성형 AI 데이터 프라이버시를 보호하고 보안을 강화하기 위한 완화 전략을 요약한다.
- HO-3.2.3 (H0) 제공된 생성형 AI 테스트 사례 연구에서 데이터 프라이버시와 보안 리스크를 인식한다.

#### 3.3 소프트웨어 테스트에서 생성형 AI 의 에너지 소비와 환경 영향

- GenAI-3.3.1 (K2) 작업 특성과 모델 사용이 소프트웨어 테스트에서 생성형 AI 의 에너지 소비에 미치는

는 영향을 설명한다.

HO-3.3.1 (H1) 시뮬레이터를 사용해 제공된 테스트 작업에 대한 생성형 AI의 에너지와 CO<sub>2</sub> 배출량을 계산한다.

### 3.4 AI 규정, 표준 및 모범 사례 프레임워크

GenAI-3.4.1 (K1) 소프트웨어 테스트에서 GenAI와 관련된 AI 규정, 표준, 모범 사례 프레임워크의 예를 상기한다.

## 3.1 환각, 추론 오류, 편향

GenAI 시스템, 특히 LLM은 환각, 추론 오류, 편향과 같은 특정 결함에 취약합니다. 이러한 결함은 GenAI 출력의 품질을 저하시켜, 생성된 테스트웨어가 테스터의 기대를 충족시키지 못하는 결과를 낳습니다. 테스터는 이러한 환각, 추론 오류, 편향을 LLM 출력에서 찾아내야 하며, 이러한 리스크를 완화하기 위한 조치를 취해야 합니다.

LLM의 비결정론적 행동(1.1.2절 참조)은 이러한 유형의 결함을 수정하기 어렵게 만듭니다. 어느 LLM 출력에서는 수정된 것처럼 보이지만, 동일한 LLM과의 다른 대화에서 다시 나타날 수 있습니다.

### 3.1.1. 생성형 AI의 환각, 추론 오류, 편향

환각은 LLM이 사실적으로 부정확하거나 주어진 작업과 관련 없는 결과물을 생성할 때 발생합니다. 소프트웨어 테스트에서 환각은 LLM이 허구적이거나 관련 없는 테스트 케이스를 만들거나, 정확하지 않거나 작동하지 않는 테스트 스크립트를 생성하거나, 존재하지 않는 인수 조건을 검증하는 테스트 케이스를 제안하는 형태로 나타날 수 있습니다. 이는 테스터를 오도하고 테스트 결과의 타당성을 훼손할 수 있습니다.

추론 오류는 LLM이 인과 관계, 조건부 논리, 단계별 문제 해결 과정과 같은 논리적 구조를 잘못 해석해 잘못된 결론에 도달할 때 발생합니다. 인간과 달리 LLM은 논리적 추론 능력이 부족하고 패턴 매칭에 의존하기 때문에, 수학적 추론과 같은 작업을 수행할 때 논리적 오류로 이어질 수 있습니다. 테스트 계획 수립과 테스트 케이스 우선순위 지정은 논리적 추론이 필요하며, LLM이 추론 오류를 범할 수 있는 테스트 작업의 예시입니다.

LLM 편향(Gallegos 2024)은 모델을 훈련시킨 데이터에서 시작됩니다. 이러한 편향은 특정 유형의 정보, 접근법 또는 가정을 선호하는 결과로 이어질 수 있습니다. 예를 들어, 주로 영어 데이터로 훈련된 LLM은 비영어권 관점을 충분히 반영하지 못할 수 있습니다. 가령, 소프트웨어 테스트에서 편향은 테스트 데이터를 생성하거나 테스트 케이스에 대한 인수 조건을 개선할 때 LLM 응답에 영향을 미칠 수 있습니다.

GenAI 출력의 환각, 추론 오류, 편향은 훈련 데이터의 특성과 트랜스포머 모델의 내재된 한계(1장 참조)에서 비롯됩니다. 이러한 과제를 인식하고 해결함으로써 테스트 프로세스에서 생성형 AI 결과의 품질을 높일 수 있습니다.

### 3.1.2. LLM 출력에서 환각, 추론 오류, 편향 식별하기

GenAI 시스템을 소프트웨어 테스트에 효과적으로 통합하려면 LLM 출력에서 환각, 추론 오류, 편향을 탐지하는 능력이 필요합니다. 문제 유형에 따라 다른 탐지 접근법을 적용할 수 있습니다. 다음은 리뷰 또는 리뷰와 자동화된 검증의 결함을 통해 적용되는 일반적인 접근법입니다:

#### 환각 탐지:

- 교차 검증: AI가 생성한 출력을 기존 문서, 요구사항, 알려진 시스템 동작과 비교합니다. 자동화 도구는 출력물을 기존 데이터 소스와 상호 참조해 불일치하는 부분을 표시하는 데 도움을 줄 수 있습니다.
- 도메인 전문가 자문: 생성된 콘텐츠의 정확성을 검증하기 위해 해당 분야의 전문가를 참여시킵니다. 이들의 전문성은 자동화된 시스템이 놓칠 수 있는 미묘한 통찰력을 포착하는 데 필수적입니다.
- 일관성 확인: 생성된 출력이 서로 일관되고 알려진 정보와 일치하는지 확인합니다. 자동화된 시스템은 패턴을 식별하고 불일치를 표시하는 데 도움이 될 수 있습니다.

#### 추론 오류 탐지:

- 논리적 검증: 리뷰 주기를 통해 AI가 생성한 콘텐츠의 논리적 흐름(예: 생성된 텍스트 내의 일관성, 조화, 구조화된 추론)이 일관되고 정확한지 평가합니다. 자동화된 도구가 도움이 될 수 있지만, 복잡한 경우에는 인간의 판단이 필요할 수 있습니다.
- 출력 테스트: 예를 들어, 생성된 테스트 케이스나 테스트 스크립트를 테스트 대상에 대해 실행해 테스트 결과를 검증합니다. 이는 생성되는 테스트웨어 유형에 따라 부분적으로 또는 완전히 자동화될 수 있습니다.

#### 편향 탐지:

- 생성된 테스트웨어(예: 테스트 코드나 합성 테스트 데이터)가 정의된 테스트 전략과 커버리지 요구사항을 공정하고 정확하게 반영하고 있는지 검토합니다.
- 생성된 LLM 출력에서 과소 표현된 비기능 테스트와 같은 테스트 유형 관련 편향을 평가합니다.

이러한 탐지 방법의 실제 구현은 GenAI로 수행되는 테스트 작업에서 예상되는 환각, 추론 오류, 편향의 리스크 수준에 따라 달라집니다.

#### 실습 목표 3.1.2a (H1): 소프트웨어 테스트 작업 관련 생성형 AI의 환각 실험

이 실습은 소프트웨어 테스트 지식 체계와 관련해 GenAI 환각 예시를 직접 체험해 보는 데 중점을 둡니다. 참가자들은 주어진 맥락 데이터에 존재하지 않는 무관한 기준을 추가하는 등, LLM이 무관한 요소를 만들어내는 상황에 최소 두 개 이상의 LLM을 직면하게 하는 시도를 수행합니다. 프롬프팅이 환각에 미치는 영향을 조사하기 위해 다양한 프롬프트 변형을 테스트합니다.

이 실습을 통해 소프트웨어 테스트에서 GenAI 환각을 식별하는 데 대한 이해를 높일 수 있습니다.

#### 실습 목표 3.1.2b (H1): 테스트 계획 작업에서 생성형 AI의 추론 오류 실험

이 실습은 GenAI 추론 오류의 예시를 제시하는 데 중점을 둡니다. 테스트 노력 추정과 테스트 케이스

우선순위 지정과 같이, 테스트 계획 영역에서 해결해야 할 문제의 예시를 다룹니다 ([ISTQB\_CTFL\_SYL] - 5장 참조). 이 실습은 문제 해결 능력을 요구하는 일정 수준의 복잡성을 가진 입력 데이터로 설계되었으며, 이러한 목적에서 LLM이 가지는 한계를 분명하게 보여줍니다. LLM의 결과물은 실제 달성해야 하는 정확한 결과와 비교됩니다. 세 가지 서로 다른 LLM 유형(대형 언어 모델(LLM), 소형 언어 모델(SLM), 추론 모델(Reasoning model))을 시도하며, 결과를 개선하기 위해 다양한 프롬프트 변형을 사용합니다.

이 실습은 논리적 문제 해결 능력을 필요로 하는 소프트웨어 테스트 작업에서 생성형 AI의 추론 오류를 식별하는 방법에 대한 이해를 높여줍니다.

### 3.1.3. 소프트웨어 테스트 작업에서 GenAI 환각, 추론 오류, 편향 완화 기법

소프트웨어 테스팅에서 GenAI의 바람직하지 않은 결과를 최소화하기 위해, 환각, 추론 오류, 편향을 줄이기 위한 여러 전략을 사용할 수 있습니다. 이러한 문제는 프롬프트가 제대로 설계되지 않았거나(2장 참조), 주어진 테스트 작업에 대한 관련 문맥 입력 데이터가 부족할 때 발생할 가능성이 더 높습니다. AI 환각, 추론 오류, 편향 관련 리스크를 완화하기 위한 주요 기법은 다음과 같습니다:

- **완전한 컨텍스트 제공:** 프롬프트에 모든 관련 정보가 포함되도록 해서(2.1.1절 참조), AI가 정확한 결과를 생성하도록 안내하는 포괄적인 컨텍스트를 제공합니다.
- **프롬프트를 관리 가능한 단계로 나누기:** 프롬프트 체이닝 기법을 사용해서(2.1.2절 참조), 복잡한 프롬프트를 더 작은 단계로 나누고, 다음 단계로 이동하기 전에 각 출력을 체계적으로 검증합니다. 이 단계별 접근법은 생성 프로세스 초기에 추론 오류를 탐지하도록 지원합니다.
- **명확하고 해석 가능한 데이터 형식 사용:** GenAI가 해석하기 모호하거나 어려울 수 있는 형식을 피합니다. 구조화되고 직관적인 형식은 모델이 작업의 본질적인 측면에 집중하도록 지원합니다.
- **작업에 적합한 GenAI 모델 선택:** 당면한 작업에 특별히 고안되어 훈련된 LLM을 사용합니다(5.1.3절 참조).
- **여러 모델 간 결과 비교:** 적절한 경우, 여러 LLM으로 프롬프트를 평가하고 출력을 비교함으로써 출력 오류를 탐지하고 가장 신뢰할 수 있는 결과를 선택하도록 지원합니다.

4장에서는 LLM 결과 개선을 위한 두 가지 보완적인 기법인 검색 증강 생성과 미세 조정을 소개합니다.

### 3.1.4. LLM의 비결정론적 행동 완화

LLM의 내재된 비결정론적 행동은 동일한 입력이 제공될 때도 출력의 변동을 초래할 수 있습니다. 이는 추론 중 사용되는 확률적 샘플링 프로세스에서 비롯됩니다. 결과적으로, LLM을 사용할 때 일관되고 재현 가능한 결과를 얻는 것이 어려울 수 있으며, 특히 긴 출력의 경우 변동성 리스크가 증가합니다.

완전한 재현성을 보장할 수는 없지만, 특정 전략이 변동성을 줄이는 데 도움이 될 수 있습니다:

- **LLM의 온도 파라미터(Temperature Parameter) 설정 조정:** 응답 생성(추론) 과정에서 온도를 낮추면 확률 분포가 좁아져 무작위성이 줄고 더 일관된 출력이 생성됩니다. 그러나 이는 창의성과 응답의 다양성을 제한해 출력이 더 반복적이거나 지나치게 결정론적이 되도록 합니다.
- **랜덤 시드(Random Seed) 설정:** 일부 LLM 구현에서는 난수 생성기에 시드값을 설정할 수 있도록 지원하며, 동일한 의사-난수(즉, 결정론적 무작위 값) 시퀀스가 사용되도록 보장해 재현성을 향상시킵니다.

LLM 출력에서 환각 및 추론 오류의 리스크를 줄이는 것은 이러한 비결정론적 행동을 해결하는 것을 포함합니다. 예를 들어, 출력 검증의 특정 측면을 자동화함으로써 구조화되고 일관된 평가 프로세스를 확보하는 방식 등이 그것입니다.

## 3.2 소프트웨어 테스트에서 생성형 AI의 데이터 프라이버시와 보안 리스크

테스팅에서의 GenAI는 민감한 정보 처리와 LLM 기반 테스트 인프라의 잠재적 취약점으로 인해 데이터 프라이버시와 보안 관련 리스크를 야기합니다. 침해, 무단 접근, 기밀 데이터 노출을 방지하기 위해 강력한 데이터 보호가 필수적입니다.

### 3.2.1. 생성형 AI 사용 관련 데이터 프라이버시와 보안 리스크

GenAI는 민감하거나 개인 식별이 가능한 정보가 포함될 수 있는 대량의 데이터를 처리할 수 있습니다. 이는 다음과 같은 데이터 프라이버시 우려를 제기합니다:

- **의도하지 않은 데이터 노출:** GenAI 모델이 우연히 민감한 정보를 드러내는 출력을 생성할 수 있습니다.
- **데이터 사용에 대한 통제 부족:** GenAI 도구가 명시적인 사용자 동의나 통제 없이 민감한 데이터를 저장하고 처리할 수 있습니다. 이는 잠재적인 오용이나 무단 접근으로 이어질 수 있습니다.
- **규정 준수 리스크:** GDPR(일반 데이터 보호 규정)과 같은 데이터 보호 규정을 준수하지 않고 GenAI 도구를 사용하면 법적 분쟁으로 이어질 수 있습니다.

또한, GenAI로 테스트할 때 다음과 같은 특정 보안 리스크가 발생할 수 있습니다:

- LLM 기반 테스트 인프라는 데이터 침해나 무단 접근과 같은 보안 공격에 취약할 수 있습니다.
- 악의적인 행위자는 LLM의 취약점(예: 조작 공격, 3.2.2절 참조)을 이용해 그 행동을 변경하거나 민감한 정보를 추출할 수 있습니다.
- 공격자는 의도적으로 악의적인 입력 데이터를 주입해 LLM을 오도하고 정확성이나 보안을 훼손할 수 있습니다.

### 3.2.2. 테스트 프로세스와 도구에서 생성형 AI의 데이터 프라이버시 및 취약점

다음 표는 GenAI 테스트 프로세스와 도구의 공격 벡터 관련 몇 가지 예시를 보여줍니다:

| 공격 벡터    | 설명                                       | 예시                                                                                   |
|----------|------------------------------------------|--------------------------------------------------------------------------------------|
| 컨텍스트 조작  | 기밀 훈련 데이터를 추출하도록 설계된 요청 보내는 것            | 긴 프롬프트로 LLM의 컨텍스트 창을 초과해 AI의 메모리에 과부하를 줌으로써, 모델이 훈련 데이터의 무작위 파편을 드러내고 민감한 정보를 노출시킨다. |
| 요청 조작    | AI의 출력을 방해하는 데이터를 주입하는 것                 | AI를 다른 컨텍스트로 유인하는 이미지를 사용해 인수 조건 등에 환각을 일으킨다.                                        |
| 데이터 포이즈닝 | 훈련 데이터를 조작하는 것                           | AI가 생성한 테스트 보고서의 결과를 평가할 때 가짜 평가를 제공한다.                                              |
| 악성 코드 생성 | LLM을 조작해 사용 중에 백도어(예: 외부 명령어 호출)를 생성하는 것 | 특정 악성 IP와 통신 채널을 여는 코드 생성한다.                                                         |

### 3.2.3. 소프트웨어 테스트에서 생성형 AI의 데이터 프라이버시 보호 및 보안 강화를 위한 완화 전략

GenAI가 주류가 되고 내재된 리스크가 커짐에 따라, 이를 완화하기 위한 규정과 표준이 등장하고 있습니다 (3.4.1절 참조).

GDPR과 같은 데이터 보호 규정은 GenAI의 적용을 명시적으로 제한하지는 않지만, 데이터 수집, 처리, 저장의 합법성, 목적 제한 관련 가능한 일을 제한하는 안전 장치를 제공합니다.

이러한 리스크를 완화하기 위해 조직은 다음과 같은 강력한 데이터 프라이버시 조치를 구현해야 합니다:

- **데이터 최소화:** 법적으로 허용되지 않는 한 민감한 데이터의 처리를 피하고, GenAI를 활용한 테스트에서는 필요한 최소한의 민감하지 않은 테스트 데이터만을 사용해 데이터 개인정보 보호 위험을 줄입니다.
- **데이터 익명화와 가명화:** 민감한 정보를 마스킹하거나 식별 불가능한 데이터로 대체합니다.
- **안전한 데이터 저장과 전송:** 강력한 암호화 및 접근 제어를 구현합니다.
- **리소스 교육:** 조직은 GenAI 도구의 책임 있는 사용을 보장하고, 윤리적 실천법을 장려하며, 잠재적 리스크를 완화하기 위해 명확한 교육 프로그램과 정책을 수립해야 합니다.

테스팅에 GenAI를 구현할 때 다음과 같은 추가적인 완화 전략을 고려할 수 있습니다:

- **생성된 결과물의 체계적인 검토:** 인간의 평가는 GenAI 기반 테스트 작업의 품질과 정확성을 보장하는 데 필수적입니다.
- **다른 LLM과의 비교 평가:** 주어진 작업에 대해 여러 LLM을 사용해 응답을 비교함으로써 출력물을 평가합니다.

- **안전한 운영 환경 선택:** 요구되는 기밀 수준에 따라 조직은 다양한 보안 솔루션을 선택할 수 있습니다: LLM 제공업체의 상용 보안 솔루션 사용, 안전한 클라우드에서 LLM 운영, 조직의 인프라에 LLM 설치 등.
- **정기적인 보안 감사와 취약점 평가:** GenAI 시스템의 약점을 식별하고 해결합니다.
- **보안 모범 사례 최신 정보 유지:** 최신 보안 지침 및 기술을 최신 상태로 유지합니다.

이러한 전략들은 종종 서로 보완적이며, GenAI를 사용하면서 데이터 보안을 보장하기 위해서는 이들의 조합이 필요합니다. 조직에 상주하는 경우, 수석 보안 엔지니어, 법률 고문, 최고 기술 책임자(CTO) 또는 최고 정보 보안 책임자(CISO)와 협력하는 것이 필요합니다.

**실습 목표 3.2.3 (H0): 제공된 생성형 AI 테스트 사례 연구에서 데이터 프라이버시와 보안 리스크 인식**  
이 시연은 소프트웨어 테스트에서 GenAI를 사용할 때 데이터 프라이버시와 보안 리스크가 어떻게 발생할 수 있는지 보여줍니다. 참가자들은 모델 취약성, 무단 데이터 접근, 생성된 결과물의 악의적 사용과 같은 잠재적 위협을 찾아내기 위해 사례 연구를 탐색합니다. 또한 윤리적 및 실용적 함의를 숙고하는 동시에 안전한 데이터 처리, 강력한 접근 제어, AI 모니터링 실천법을 포함한 완화 전략을 모색합니다.

마지막으로 참가자들은 데이터 프라이버시 원칙을 이해하고 GenAI 테스트 컨디션에서 보안 리스크를 인식하고 해결하는 방법을 배우게 됩니다.

### 3.3 소프트웨어 테스트에서 생성형 AI의 에너지 소비와 환경 영향

연구에 따르면 LLM을 훈련하고 처리하는 데는 많은 수의 전문적인 컴퓨팅 자원의 집중적인 사용이 필요합니다. LLM은 웹 기반 서비스로 제공되며, 그 사용은 장치, 네트워크, 데이터 센터의 부하를 증가시켜 더 높은 에너지 소비로 이어집니다.

#### 3.3.1. GenAI 사용이 에너지 소비와 CO2 배출에 미치는 영향

GenAI의 환경적 영향은 과소평가될 수 없으며, 사용량이 증가함에 따라 에너지 소비가 급격히 증가합니다. 작업의 복잡성과 필요한 컴퓨팅 리소스가 에너지 소비에 영향을 미칩니다. 예를 들어, 강력한 AI 모델로 단일 이미지를 생성하는 데 드는 에너지는 스마트폰을 완전히 충전하는데 필요한 에너지와 비슷할 수 있지만, 텍스트를 생성하는 데는 아주 적은 에너지만 들어갑니다 (Heikkilä 2023).

GenAI의 환경 영향에 대한 정확한 데이터를 얻기는 어렵지만(Luccioni 2024b), 이러한 에너지 집약적인 작업들이 결과적으로 상당한 CO<sub>2</sub> 배출을 유발한다는 점은 분명합니다 (Berthelot 2024). 단일 검색이나 텍스트 생성 작업은 미미해 보일 수 있지만, 전 세계 수백만 명의 사용자에게 걸친 누적 효과는 엄청난

환경적 부담을 초래합니다.

불필요한 모델 상호작용을 제한하는 등의 모범 사례를 채택하는 것은 GenAI가 제기하는 환경 리스크를 완화하는 데 중요합니다.

#### 실습 목표 3.3.1 (H1): 시뮬레이터를 사용해 주어진 테스트 작업에 대한 생성형 AI의 에너지와 CO<sub>2</sub> 배출량 계산

이 실습은 소프트웨어 테스트 내 다양한 생성형 AI 작업의 에너지 소비와 관련 CO<sub>2</sub> 배출량을 평가하는 데 중점을 둡니다. 참가자들은 시뮬레이션을 사용해 이러한 메트릭을 계산하고 다양한 작업 특성과 모델 사용이 환경에 미치는 영향을 조사합니다. 다양한 요인이 에너지 소비와 배출에 어떤 영향을 미치는지 관찰함으로써 참가자들은 LLM을 사용한 에너지 소비의 요인을 이해하게 됩니다.

### 3.4 AI 규정, 표준 및 모범 사례 프레임워크

GenAI는 다양한 테스트 작업을 지원함으로써 소프트웨어 테스트를 변화시키고 있습니다 (2장 참조). 그러나 이러한 기회는 추론 오류, 데이터 프라이버시, 취약성, 환경 영향과 같은 중대한 리스크를 동반합니다 (3.1, 3.2, 3.3절 참조). 이러한 리스크를 해결할 때는 AI에 대한 일반적인 규정, 표준, 모범 사례 프레임워크를 고려해야 합니다.

#### 3.4.1. 소프트웨어 테스트에서 GenAI와 관련된 AI 규정, 표준, 프레임워크

다음은 소프트웨어 테스트에서 GenAI 사용과 관련된 주요 지침의 개요입니다:

| 이름 / 유형                                                                | 설명                                                                           | 소프트웨어 테스트에서의 적용                                           |
|------------------------------------------------------------------------|------------------------------------------------------------------------------|-----------------------------------------------------------|
| <b>ISO/IEC 42001:2023</b> 정보 기술-인공 지능-관리 시스템<br>유형: 표준                 | 조직 내에서 AI 시스템을 관리하기 위한 요구사항을 명시합니다.                                          | 테스팅 분야의 GenAI가 권장 실천법을 준수하도록 유도하며, 일관성과 신뢰성을 높입니다.        |
| <b>ISO/IEC 23053:2022</b> 머신 러닝을 사용하는 인공지능(AI) 시스템을 위한 프레임워크<br>유형: 표준 | AI 수명주기 프로세스에 대한 프레임워크를 제공하며, 안전성과 투명성을 강조합니다.                               | 테스팅에 GenAI를 사용할 때 데이터 품질, 투명성, 안전성을 보장하기 위한 프레임워크를 제공합니다. |
| <b>EU AI Act</b><br>유형: 규정                                             | AI 리스크를 다루는 법적 프레임워크를 수립하고, 애플리케이션을 리스크 수준별로 분류합니다.<br>Source: (AI Act 2024) | 테스팅에 사용되는 GenAI에 대해 투명성, 책임성, 편향 완화 준수를 의무화합니다.           |

|                                                                   |                                                                        |                                                      |
|-------------------------------------------------------------------|------------------------------------------------------------------------|------------------------------------------------------|
| <b>NIST AI Risk Management Framework (미국)</b><br><b>유형:</b> 프레임워크 | 공정성, 투명성 및 보안에 중점을 둔 AI 리스크 관리 지침을 제공합니다.<br>Source: (NIST AI RMF 1.0) | GenAI의 공정성을 지원하고 리스크를 완화해 편향된 테스트 결과가 발생하는 것을 방지합니다. |
|-------------------------------------------------------------------|------------------------------------------------------------------------|------------------------------------------------------|

AI 기술과 규제 환경이 계속 발전함에 따라, 테스트 조직은 이 표에 있는 것들과 같은 규정, 표준, 국내 법, 모범 사례 프레임워크 등에 대한 최신 정보를 유지하는 것이 필수적입니다.

## 제 4 장 소프트웨어 테스트를 위한 LLM 기반 테스트 인프라

110분

### 용어

테스트 인프라(test infrastructure)

### 생성형 AI 관련 특정 용어

미세 조정(fine-tuning), LLM 기반 에이전트(LLM-powered agent), 거대 언어 모델 운영(Large Language Model Operations), 검색 증강 생성(retrieval-augmented generation), 벡터 데이터베이스(vector database)

### 4장 학습 목표 및 실습 목표:

#### 4.1 LLM 기반 테스트 인프라를 위한 아키텍처 접근법

- GenAI-4.1.1 (K2) LLM 기반 테스트 인프라의 주요 아키텍처 구성요소와 개념을 설명한다.
- GenAI-4.1.2 (K2) 검색 증강 생성을 요약한다.
- HO-4.1.2 (H1) 주어진 테스트 작업에 대해 검색 증강 생성을 실험한다.
- GenAI-4.1.3 (K2) 테스트 프로세스 자동화에서 LLM 기반 에이전트의 역할과 적용을 설명한다.
- HO-4.1.3 (H0) LLM 기반 에이전트가 반복적인 테스트 작업 자동화에 기여하는 바를 관찰한다.

#### 4.2 미세 조정과 LLMOps: 소프트웨어 테스트를 위한 생성형 AI 운영화

- GenAI-4.2.1 (K2) 특정 테스트 작업을 위한 언어 모델의 미세 조정을 설명한다.
- HO-4.2.1 (H0) 주어진 테스트 작업과 언어 모델에 대한 미세 조정 프로세스 예제를 관찰한다.
- GenAI-4.2.2 (K2) LLMOps 와 테스트 작업을 위한 LLM 배포와 관리에서의 역할을 설명한다.

## 4.1 LLM 기반 테스트 인프라를 위한 아키텍처 접근법

AI 챗봇과 LLM 기반 테스트 도구는 LLM을 사용하는 두 가지 유형의 테스트 인프라입니다(1.2.2절 참조). LLM 기반 테스트 인프라의 기본 아키텍처(4.1.1절 참조)를 넘어, 검색 증강 생성(4.1.2절 참조)과 LLM 기반 에이전트 아키텍처(4.1.3절 참조)는 소프트웨어 테스팅에서 LLM 사용의 기능성과 유용성을 확장합니다.

### 4.1.1. LLM 기반 테스트 인프라의 주요 아키텍처 구성요소와 개념

LLM 기반 테스트 인프라는 자동화, 추론, 의사 결정을 향상시키기 위해 LLM을 테스트 프로세스에 통합한 시스템을 의미합니다. 주로 대화형 상호작용에 초점을 맞춘 전통적인 AI 챗봇과 달리, LLM 기반 테스트 도구는 테스트 관련 쿼리 처리, 요구사항 분석, 테스트 케이스 생성, 출력 평가를 통해 소프트웨어 테스팅을 지원하도록 설계되었습니다.

LLM 기반 테스트 인프라의 일반적인 아키텍처는 LLM과의 안전하고 효율적인 상호작용을 용이하게 하는 다중 구성요소 설계를 따릅니다. 이 아키텍처는 프론트엔드와 백엔드 구성요소, 그리고 외부 데이터 소스와 통합된 LLM으로 구성됩니다:

- **프론트엔드**는 테스터가 쿼리나 명령어를 입력해 시스템과 상호작용하는 사용자 인터페이스 역할을 합니다.
- **백엔드**는 사용자 입력을 처리하고 인증, 데이터 검색, 프롬프트 준비, LLM과의 상호작용과 같은 중요한 기능을 관리합니다.
- **LLM**은 API를 통해 접근하는 서드파티 서비스 또는 맞춤형 사내 모델로 호스팅될 수 있으며, 구조화된 프롬프트를 기반으로 응답을 생성합니다.

이 아키텍처는 LLM 및 다중 소스 백엔드와 같은 지능형 처리 구성요소를 통합함으로써 전통적인 클라이언트-서버 모델을 뛰어넘습니다:

1. LLM은 단순한 서버가 아니라 테스트웨어를 기반으로 해석하고 추론하는 지능형 처리 구성요소입니다.
2. 스크립트화된 응답을 따르는 규칙 기반 챗봇과 달리, LLM 기반 테스트 인프라는 요구사항이나 코드 또는 테스트 결과와 같은 컨텍스트로부터 동적으로 테스트 인사이트를 생성합니다.
3. 백엔드는 다음과 같은 다양한 데이터 소스를 통합합니다:
  - 관계형 데이터베이스 (테스트 케이스와 같이 테스팅에 사용되는 구조화된 데이터용)
  - 벡터 데이터베이스 (임베딩을 사용한 관련 콘텐츠의 의미론적 검색용; 4.1.2절 참조)
4. 백엔드는 LLM의 원시 출력을 후처리해 개선함으로써, 프론트엔드에 전달하기 전에 응답이 테스트 프로세스의 테스트 조건과 일치하도록 보장합니다.

#### 4.1.2. 검색 증강 생성 (Retrieval-Augmented Generation, RAG)

검색 증강 생성(RAG)은 추가 데이터 소스를 응답 생성 프로세스에 통합해 LLM을 향상시켜(Zhao 2024), 결과물의 관련성과 정확성을 높입니다.

RAG(검색 증강 생성)는 검색 시스템과 언어 모델을 결합해 문맥을 인식하는 응답을 생성합니다. 전처리 단계에서 대형문서는 모델의 컨텍스트 창과의 호환성을 확보하고 집중된 검색이 가능하도록 더 작은 청크(예: 256-512 토큰)로 분할됩니다. 각 청크는 사전 훈련된 모델을 통해 정제 및 처리된 후 고차원 벡터(임베딩)로 인코딩됩니다. 이러한 임베딩은 벡터 데이터베이스에 저장될 수 있는데, 이는 실행 시점(추론)에 유사도 기반의 효율적인 검색을 가능하게 합니다. 사용자 쿼리는 인코딩되면 의미론적 유사성을 기반으로 관련 청크를 검색하며, 이 청크들은 언어 모델이 근거 있는 응답을 생성하기 위한 컨텍스트로 사용됩니다.

관련성 높은 응답은 본질적으로 검색 과정에서 수집된 관련성 있고, 정확하며, 문맥적으로 적절한 정보에 깊이 뿌리를 둔 언어 모델에 의해 생성된 출력입니다. 이는 응답이 모델의 사전 학습 데이터뿐만 아니라, 프롬프트와 직결된 정확한 데이터로 보강된다는 것을 의미합니다. 이러한 검색과 생성 간의 시너지 효과는 응답의 정확성과 연관성을 높여, 사용자가 더 신뢰할 수 있고 더 유익한 정보를 제공합니다.

사용자 프롬프트 처리 단계에서 RAG 시스템은 다음 2단계 프로세스를 통해 작동합니다:

1. **검색:** 사용자 쿼리가 주어지면, 시스템은 이전에 생성된 벡터 데이터베이스에서 관련 정보를 검색합니다. 이 검색은 일반적으로 프롬프트의 임베딩과 청크의 임베딩 간의 의미론적 유사성을 기반으로 합니다.
2. **생성:** 검색된 정보는 LLM에 전달되어, 기존 지식과 새로 획득한 데이터를 결합한 응답을 생성하며, 결과적으로 더 정확하고 문맥에 맞는 출력이 나옵니다.

소프트웨어 테스트에서 RAG는 LLM 기반 테스트 인프라가 데이터베이스, 문서, 저장소와 같은 회사의 기업 데이터 소스에 접근해 실시간으로 문맥 정보를 검색할 수 있게 합니다. 이는 테스트 분석이나 테스트 설계 등의 테스트 작업이 최신 명세, 요구사항, 기존 테스트 데이터와 일치하도록 보장합니다.

##### 실습 목표 4.1.2 (H1): 주어진 테스트 작업에 대해 검색 증강 생성을 실험

이 실습은 주어진 테스트 작업에 대한 RAG 기법의 적용에 중점을 둡니다. 참가자들은 문서를 통합해 RAG 시스템을 실험하고 복잡한 정보를 기반으로 더 정확하거나 덜 정확한 답변을 생성하는 방법을 관찰합니다. 참가자들은 주어진 테스트 작업에 대해 RAG가 있거나 없는 LLM의 출력을 비교합니다. 이 실습은 다양한 유형의 테스트 작업 처리에서 RAG 시스템의 강점과 한계를 식별하는 것을 목표로 합니다.

검색된 데이터와 생성된 결과를 검토함으로써 참가자들은 LLM 기반 테스트 프로세스를 향상시키는 데 있어 RAG의 역할에 대한 통찰력을 얻게 될 것입니다.

### 4.1.3. 테스트 프로세스 자동화에서 LLM 기반 에이전트의 역할 및 적용

LLM 기반 에이전트(Wang 2024)는 LLM에 의해 구동되는 특화된 GenAI 애플리케이션으로, 정의된 작업을 반자율적 또는 자율적으로 처리하도록 설계되었습니다. 이러한 에이전트는 핵심적으로 자연어 이해 및 생성을 위해 LLM에 의존하며, 지시사항 처리, 컨텍스트 검색, 지능적 행동 수행 기능으로 보완됩니다.

단순한 질의-응답 상호작용에만 초점을 맞춘 기존 AI 챗봇과 달리, LLM 기반 에이전트는 일반적으로 "도구" 라고 불리는 사전 정의된 함수 집합을 호출해 작업을 수행하거나 "행동"할 수 있습니다. 이런 기능을 통해 외부 시스템과 상호작용하고 이를 제어할 수 있어 작업 실행 시 높은 다재다능함을 보여줍니다. LLM 기반 에이전트의 자율성 정도는 다음과 같이 나뉠 수 있습니다:

- 자율적 에이전트: 사전 정의된 규칙, 강화 학습, 적응형 피드백 루프를 사용해 최소한의 인간 개입으로 독립적으로 작업을 수행합니다.
- 준자율적 에이전트: 출력이 사용자 정의 목표를 충족하는지 확인하기 위해 주기적인 인간의 감독 하에 작업을 수행합니다.

다중 에이전트 아키텍처는 각각 특화된 역할을 가진 여러 에이전트가 단일 에이전트보다 더 효율적으로 복잡한 문제를 해결하기 위해 소통하고 조율하는 협업 시스템을 포함합니다. 여러 AI 에이전트 간의 이러한 체계적인 협업을 "오케스트레이션(orchestration)"이라고 하며, 여기서 LLM 기반 에이전트는 인간의 추론과 의사결정을 모방해 테스트 작업을 자동화할 수 있습니다.

최신 테스트 도구에서 LLM 기반 에이전트는 종종 테스트 워크플로우에 통합된 AI 어시스턴트를 통해 사용자에게 제공됩니다. 이러한 어시스턴트는 사용자 스토리와 요구사항을 테스트 산출물로 변환함으로써 전체 테스트 수명주기에 걸쳐 테스트 활동을 자동화할 수 있습니다. 여기에는 테스트 분석, 테스트 설계, 테스트 구현, 테스트 실행, 테스트 보고를 반자율적으로 수행하는 것이 포함됩니다. 이를 통해 수동 작업을 줄이고 피드백 주기를 단축하는 연속적인 엔드투엔드(end-to-end) 자동화 워크플로우가 가능해지며, 동시에 테스트 자동화를 스크립트 기반 실행에서 목표 지향적인 에이전트 기반 테스트 자동화로 전환합니다.

그러나 이러한 에이전트는 LLM을 사용할 때 관찰되는 가능한 환각, 추론 오류, 편향과 동일한 문제로 어려움을 겪습니다 (3.1절 참조). 이러한 에이전트는 부정확하거나 오해의 소지가 있는 결과를 생성할 수 있으며, 따라서 자동화된 테스트 프로세스의 신뢰성을 약화시킬 수 있습니다. 이러한 리스크는 에이전트 결과에 대한 자동화된 검증 절차를 구현하거나 중요한 작업에 반자율적 에이전트를 사용해 완화할 수 있습니다.

#### 실습 목표 4.1.3 (H0): LLM 기반 에이전트가 반복적인 테스트 작업을 자동화에 기여하는 방법 관찰

이 실습은 LLM 기반 에이전트가 수행하는 테스트 작업에 중점을 둡니다. 에이전트에 전달된 입력 데이터, 그 행동과 결과를 시연해 에이전트 기반 솔루션을 테스트 프로세스에 통합하는 여러 측면을 보여줍니다. 이 시연은 테스트 작업의 맥락에서 LLM 기반 에이전트의 구체적인 예를 보여줍니다.

## 4.2 미세 조정과 LLMOps: 소프트웨어 테스트를 위한 생성형 AI 운영화

테스팅을 위한 LLM 기반 테스트 인프라를 운영하기 위한 두 가지 핵심 실천법으로 LLM 미세 조정과 LLMOps를 통한 운영 파이프라인 관리가 있습니다.

### 4.2.1. 특정 테스트 작업을 위한 언어 모델 미세 조정

미세 조정은 사전 훈련된 언어 모델(LLM이나 소형 언어 모델(SLM, 1.1.2절 참조))을 조정해 특정 작업을 수행하거나 특정 도메인에 맞춤화하는 과정입니다 (Parthasarathy 2024). 여기에는 대상 데이터셋으로 모델을 추가 훈련시켜 도메인별 지식과 뉘앙스를 학습하게 하는 것을 포함합니다. 미세 조정을 통해 특정 애플리케이션에 대한 모델 성능이 향상되며, 의도한 유스케이스에 더 정확하고 연관성 높은 응답을 제공하게 됩니다.

실제로 미세 조정은 일반 LLM에 특정 도메인과 관련된 전문적인 추론 능력을 갖추게 하거나, 해당 분야 고유의 어휘를 채택하도록 만드는 데 적합합니다. 미세 조정은 자원 집약도가 낮은 소형 모델인 SLM에도 적용할 수 있습니다. SLM을 미세 조정함으로써 LLM에 필요한 막대한 컴퓨팅 오버헤드 없이도 특정 작업에 대해 더 높은 성능 수준을 달성할 수 있습니다. 이러한 비교는 특정 작업의 구체적인 요구사항에 따라 LLM과 SLM을 모두 사용하는데 있어 유연성과 효율성이 중요함을 보여줍니다.

예를 들어, 소프트웨어 테스트에서 미세 조정은 LLM 또는 SLM이 사용자 스토리에서 조직의 컨텍스트에 특화된 출력 형식으로 테스트 케이스를 생성할 수 있게 합니다. 조직의 사용자 스토리와 그에 상응하는 테스트 케이스로 모델을 훈련함으로써, 모델을 조직의 특정 테스트 프로세스와 용어에 일치시킬 수 있습니다.

소프트웨어 테스트를 위해 GenAI 모델을 미세 조정하는 것은 다음과 같은 몇 가지 도전 과제를 동반합니다:

- 고품질의 작업별 훈련 데이터셋을 사용해 편향되거나 부정확한 결과를 방지해야 합니다.
- 다양한 시나리오에 걸쳐 일반화 성능을 유지하기 위해 과적합(모델이 훈련 데이터에 지나치게 특화되어 새로운 미보유 데이터에 대한 성능에 부정적인 영향을 미치는 것)을 완화해야 합니다.
- 디버깅과 검증을 어렵게 만드는 모델 추론의 불투명성(LLM이 결정을 내리거나 출력을 생성하는 방식에 대한 투명성 부족)을 해결해야 합니다.
- 미세 조정 프로세스에 필요한 막대한 컴퓨팅 자원을 관리해야 합니다(LLM의 경우).

#### 실습 목표 4.2.1 (H0): 주어진 테스트 작업과 언어 모델에 대한 미세 조정 프로세스 예제 관찰

이 시연은 주어진 테스트 작업에 맞게 LLM을 미세 조정하는 데 관련된 여러 다양한 단계를 보여줍니다. 먼저 적절한 LLM 또는 SLM을 선택하는 것부터 시작합니다. 다음으로, 주어진 테스트 작업에 맞게 조정된 데이터셋이 제시됩니다. 이어 미세 조정 프로세스에 대한 예시 솔루션(예: 머신 러닝 프레임워크)을 보여줍니다. 마지막으로, 미세 조정된 모델에 프롬프트를 전송하고 생성된 출력의 품질에 대해 논의합니다.

테스트 작업을 위한 LLM/SLM 미세 조정 프로세스의 이 실습은 해당 프로세스의 여러 핵심 측면을 보여주며, 특히 훈련 데이터의 품질을 다루게 됩니다.

### 4.2.2. 테스트 작업을 위한 LLM 배포 및 관리에서 LLMOps의 역할

LLMOps(거대 언어 모델 운영)는 프로덕션 환경에서 LLM의 개발, 배포, 유지보수를 간소화하도록 설계된 실천법, 도구, 프로세스의 집합을 의미합니다.

조직의 테스트 프로세스에서 생성형 AI를 사용하는 방법은 몇 가지 다른 방식으로 달성될 수 있으며, 이는 결정해야 할 LLMOps 항목에 영향을 미칩니다. 세 가지 가능한 접근법은 다음과 같습니다:

- **AI 챗봇 사용:** 이 접근법의 주요 고려 사항은 데이터 프라이버시와 보안 리스크를 관리하면서 비용을 최적화하는 것입니다. 조직은 필요한 보장이 제공되는 경우 LLM-as-a-Service 플랫폼을 사용하거나, 더 강력한 통제력 확보를 위해 오픈 소스 라이선스 LLM을 사용해 사내 인프라를 구축할 수도 있습니다. 배포할 수 있습니다. 데이터 프라이버시와 보안 리스크를 완화하고(3.2절 참조) 운영 효율성을 보장하려면 공급업체의 보장 내용이나 내부 역량에 대한 엄격한 평가가 필수적입니다.
- **GenAI 기능이 있는 테스트 도구 사용:** 이 접근법은 AI 챗봇과 유사한 고려 사항(데이터 프라이버시, 보안, 운영 비용)을 가집니다. 추가적으로, 조직은 테스트 도구 제공업체가 제공하는 데이터 보안 및 성능 보증을 평가해야 합니다. 이러한 테스트 도구는 일반적으로 기존 테스트 프로세스를 보완하므로, 철저한 비용 편익 분석과 리스크 평가가 필요합니다.
- **GenAI 기반 테스트 도구 자체 개발:** 이 접근법은 데이터 개인정보 보호 및 보안 위험에 대한 포괄적인 통제와 더불어, 컴퓨팅 자원, 데이터 저장, 직원 교육과 같은 AI 자원 활용에 대한 신중한 계획을 강조합니다. 조직은 또한 GenAI에 특화된 개발 항목을 검증하고 유지보수하기 위한 체계적인 프로세스를 수립해야 합니다. 자체 솔루션을 개발하려면 LLM 기반 테스트 인프라를 구현하고 배포하는 전문 지식이 필요합니다.

이러한 접근법들은 상호 배타적이지 않으며, 조직은 일부 작업에 AI 챗봇을 활용하면서 다른 작업에는 맞춤형 도구를 개발할 수 있습니다. 따라서 관련된 특정 테스트 활동에 따라 여러 방식이 동시에 구현될 수 있습니다. 또한, RAG 및 LLM/SLM 미세 조정과 같은 추가 기술을 통합해 GenAI를 사용한 테스트 프로세스의 효과와 적응성을 향상시킬 수 있습니다.

## 제 5 장 테스트 조직에서 생성형 AI 배포 및 통합

80분

### 생성형 AI 관련 특정 용어

새도우 AI(shadow AI)

### 5장 학습 목표 및 실습 목표:

#### 5.1 소프트웨어 테스트에서 생성형 AI 도입을 위한 로드맵

- GenAI-5.1.1 (K1) 새도우 AI 의 리스크를 상기한다.
- GenAI-5.1.2 (K2) 소프트웨어 테스트를 위한 생성형 AI 전략 수립 시 고려해야 할 주요 측면을 설명한다.
- GenAI-5.1.3 (K2) 주어진 컨텍스트에서 소프트웨어 테스트 작업을 위한 LLM/SLM 선택의 주요 기준을 요약한다.
- HO-5.1.3 (H1) 주어진 테스트 작업에 들어가는 생성형 AI 사용을 위한 반복 비용을 추정한다.
- GenAI-5.1.4 (K1) 테스트 조직에서 생성형 AI 도입의 주요 단계를 상기한다.

#### 5.2 소프트웨어 테스트를 위한 생성형 AI 도입 시 변화 관리

- GenAI-5.2.1 (K2) 테스터가 테스트 프로세스에서 생성형 AI 와 효과적으로 작업하기 위해 필요한 필수 기술과 지식 영역을 설명한다.
- GenAI-5.2.2 (K1) 테스트 활동에 생성형 AI 도입을 지원하기 위해 테스트팀 내에서 AI 역량을 배양하는 전략을 상기한다.
- GenAI-5.2.3 (K1) 생성형 AI 도입 시 테스트 조직 내에서 테스트 프로세스와 역할 및 책임이 어떻게 전환되는지 파악한다.

## 5.1 소프트웨어 테스트에서 생성형 AI 도입을 위한 로드맵

GenAI를 사용하는 테스트 전략에서는 달성할 테스트 목표, 적절한 LLM 선택, 프롬프팅에 사용되는 입력 데이터 문제, AI 표준과 규정 준수와 같은 주요 측면을 신중하게 고려해야 합니다. 이 전략을 기반으로 조직은 로드맵을 수립하고 GenAI를 테스트 프로세스에 통합하는 진행 상황을 모니터링할 수 있습니다.

### 5.1.1. 새도우 AI의 리스크

새도우 AI는 보안, 규정 준수, 데이터 프라이버시와 관련된 다음 리스크로 이어질 수 있습니다:

- **정보 보안과 데이터 프라이버시 약점:** 개인 AI 도구는 강력한 보안이 부족해 잠재적인 데이터 유출로 이어질 수 있습니다.
- **규정 준수와 규제 문제:** 승인되지 않은 AI 도구를 사용하면 산업 표준 및 규정(3.4.1절 참조)을 준수하지 않게 되어 잠재적인 법적 결과를 초래할 수 있습니다.
- **모호한 지적 재산권:** 불분명한 라이선스 계약을 가진 AI 도구의 사용은 LLM 사용자를 지적 재산권 분쟁에 노출시킬 수 있으며, 특히 저작권이 있는 데이터가 적절한 승인 없이 처리될 경우 리스크는 더 커질 수 있습니다.

GenAI를 통합하고 배포하기 위한 전략과 단계는 테스트 조직이 새도우 AI의 리스크를 피하는 데 도움이 될 수 있습니다.

### 5.1.2. 소프트웨어 테스트에서 생성형 AI 전략 수립 시 필수 고려 사항

테스팅에 GenAI 전략을 성공적으로 구현하기 위해 조직은 원활한 통합과 최적의 결과 보장을 위한 핵심 요소를 신중하게 고려해야 합니다. 이는 테스트 생산성 향상, 테스트 주기 단축, 테스트 품질 개선과 같은 GenAI에 대한 측정 가능한 테스트 목표를 정의하는 것에서 시작되며, 상황에 맞는 LLM을 선택하는 것은 매우 중요합니다 (5.1.3절 참조). 선택된 LLM은 측정 가능한 테스트 목표와 부합해야 하며, 기존 테스트 인프라와의 호환성을 보장하고 시스템 확장성 요구사항을 충족해야 합니다.

데이터 품질은 중요한 역할을 합니다. LLM 기반 테스트의 효과는 정확하고 관련성 있는 입력 데이터에 따라 달라지며, 이는 강력한 보안 절차로 보호되어야 합니다. 따라서 고품질 입력 데이터를 유지하는 것은 신뢰할 수 있는 정확한 결과를 얻는 데 핵심입니다.

테스트팀이 GenAI 도구를 효과적으로 사용하는 데 필요한 기술적, 윤리적 역량을 갖추도록 포괄적인 교육 프로그램을 제공해야 합니다. 교육 외에도, GenAI 결과 효과성 측정을 위해 특정 메트릭을 수집해야 합니다 (2.3.1절 참조).

규제 표준 및 윤리 지침 준수를 보장하기 위해, 조직은 민감한 데이터 사용 규칙, 투명성 의무(예: 무엇이 GenAI를 사용해 생성되었는지), 생성된 테스트웨어 검토를 포함한 품질 게이트 등 GenAI 사용에 대한 프로세스 지침을 수립해야 합니다.

### 5.1.3. 소프트웨어 테스트 작업을 위한 LLM/SLM 선택

다양한 LLM/SLM이 있으며, 각각 다른 기능적 능력(예: 멀티모달 입력, 추론 능력 등), 기술적 특징(예: 컨텍스트 창 크기), 라이선스 유형(예: 상용 vs 오픈 소스)을 가집니다. 자연어 처리, 코드 생성, 이미지 분석과 같은 작업을 위해 LLM/SLM을 평가하는 많은 벤치마크가 있지만, 소프트웨어 테스트 작업에 특화된 것은 많지 않습니다.

따라서 테스트 작업을 위한 LLM/SLM을 선택하려면 다음과 같은 여러 핵심 기준을 신중하게 고려해야 합니다:

- **모델 성능:** 2.3.1절에서 제시된 메트릭 등을 사용해 조직의 벤치마크에 대해 목표 테스트 작업에 대한 모델의 성능을 평가합니다.
- **미세 조정 가능성:** 특정 사용 사례에 대한 성능을 향상시키기 위해 언어 모델(LLM 또는 SLM)을 도메인별 데이터로 미세 조정하는 것이 가능하고 유용한지 평가해, 전문화된 컨텍스트에서 정확성과 관련성을 높입니다.
- **반복 비용:** 목표 테스트 작업에 대한 조직의 예산에 맞는지 확인하기 위해 라이선스 비용 및 운영 비용을 포함한 LLM/SLM 사용의 반복 비용을 고려합니다.
- **커뮤니티 및 지원:** 구현 및 문제 해결을 돕기 위해 활발한 커뮤니티 지원과 상세한 문서가 있는 모델을 선택합니다.

이러한 기준을 신중하게 평가함으로써 테스트 조직은 특정 요구사항과 조직적 제약조건을 충족하는 하나 이상의 LLM/SLM을 선택할 수 있습니다.

#### 실습 목표 5.1.3 (H1): 주어진 테스트 작업에 대해 생성형 AI 사용의 반복 비용을 추정

이 실습은 다양한 가정을 기반으로 특정 테스트 작업에 대해 GenAI를 사용에 들어가는 반복 비용을 추정하는 데 중점을 둡니다. 여기에는 입력과 출력 데이터의 토큰 수, 사용된 프롬프트와 작업 빈도 등의 요소가 포함됩니다. 여러 LLM/SLM 공급업체의 가격 모델을 탐색 및 비교하며, 적어도 하나의 상용 솔루션과 하나의 오픈 소스 라이선스 모델을 선택합니다.

이 실습은 실용적인 테스트 조건을 사용해 GenAI의 반복 비용을 계산하고 실험할 기회를 제공해 다양한 접근법과 공급업체의 재정적 함의를 이해하는 데 도움이 됩니다.

### 5.1.4. 테스트 조직에서 생성형 AI 도입의 주요 단계

테스트 조직 내에서의 GenAI 도입은 다음 세 가지 주요 단계를 포함합니다:

1. **발견 (Discovery):** 첫 번째 단계는 인식과 역량 구축에 중점을 둡니다. 활동에는 GenAI 개념에 대한 테스트팀 교육, LLM/SLM에 대한 접근 제공, 테스터가 GenAI에 익숙해지고 자신감을 가질 수 있도록 초기 사용 사례 실험 등이 포함됩니다.

2. **시작 및 사용 정의 (Initiation and usage definition):** 기본적인 이해가 확립되면, 두 번째 단계는 소프트웨어 테스트에서 GenAI의 실용적인 유스케이스를 파악하고 우선순위를 정하는 데 집중합니다. 이 단계에는 LLM 기반 테스트 인프라 평가, 전문성 개발, 조직의 요구사항과의 일치성 확보가 포함됩니다 ([ISTQB\_CTFL\_SYL] 6장 참조).
3. **활용 및 반복 (Utilization and iteration):** 이 고급 단계에서 조직은 GenAI를 테스트 프로세스에 완전히 통합합니다. 소프트웨어 테스트와 관련 도구에 대한 GenAI의 진행 상황을 지속적으로 모니터링하고, 지속 가능한 이익과 확장성을 보장하기 위한 전환을 측정하고 관리합니다.

이러한 단계들은 서로 다른 유스케이스와 병행해 진행될 수 있습니다. 예를 들어, 테스트 보고서 분석은 로드맵 상에서 더 진전된 단계에 있을 수 있는 반면, 테스트 자동화는 초기 단계에 머물러 있을 수 있습니다. 또한 도입과 팀 사기에 영향을 미칠 수 있는 직무 대체에 대한 두려움 같은 초기 우려 사항을 인식하고 해결하는 것 또한 중요합니다.

## 5.2 소프트웨어 테스트를 위한 생성형 AI 도입 시 변화 관리

테스트 조직에 GenAI를 성공적으로 구현하려면 변화 관리 프로세스에 대한 체계적인 접근법이 필요합니다. 핵심적인 측면에는 필수적인 GenAI 역량 구축과 AI 지원 테스트 프로세스를 수용하기 위한 기존의 테스트 역할을 진화시키는 것이 포함됩니다. 이러한 전환은 기술적 역량과 조직적 측면 모두를 포함합니다.

### 5.2.1. 생성형 AI 활용 테스트의 필수 기술 및 지식

테스팅에 GenAI를 성공적으로 통합하려면 프롬프트 엔지니어링 기술 숙달, 모델의 컨텍스트 창 이해, 테스트 검토 방법 개발이 필요합니다. 테스터는 테스트 케이스 생성, 결함 보고서 분석, 테스트 데이터 생성과 같은 작업에서 LLM 기반 테스트를 평가하기 위해 도메인 및 테스트 전문 지식을 AI 기술과 결합해야 합니다.

핵심 역량에는 LLM 역량 평가, 프롬프트 개선 기법 이해, AI 생성 테스트웨어 평가가 포함됩니다. 필수 지식에는 일반적인 완화 전략에 대한 인식과 함께 GenAI의 본질적인 리스크에 대한 이해가 포함됩니다. 테스터는 테스트웨어를 LLM과 공유할 때 발생할 수 있는 데이터 보안 문제를 이해해야 하고, 적절한 데이터 비식별화(민감 정보, 개인 정보, 기밀 정보의 삭제 또는 마스킹)를 수행하고, 개인정보 보호 프롬프트 엔지니어링 실천법을 준수해야 합니다. 환경적 고려 사항에는 컴퓨팅 오버헤드를 줄이기 위한 모델 선택과 사용 패턴 최적화, 테스트 작업에 적절한 크기의 모델 선택, GenAI 자동화의 이점과 비용 및 에너지 소비에 미치는 영향의 균형을 맞추는 것이 포함됩니다.

### 5.2.2. 테스트팀 내 생성형 AI 역량 구축

테스팅을 위한 GenAI에 대해 테스트팀을 전략적으로 훈련시키기 위해서는 실습 중심의 접근법이 필수적입니다. 여기에는 다양한 LLM/SLM으로 실습하고, 체계적인 학습 경로를 따르며, 조직 내 지식 공유를 통해 노하우를 점진적으로 발전시키는 과정이 포함됩니다. 교육의 핵심은 가이드된 실습, 동료 학습, 일상적인 테스트 작업으로의 점진적인 AI 통합을 통해 실무 능력을 기르는 데 있습니다.

테스트팀 구성원들은 기본적인 프롬프트 작성에 익숙해지는 단계부터 시작해, 테스트에 특화된 프롬프트와 같은 더 심화된 기법을 활용하는 단계로 발전합니다. 프롬프트 패턴은 GenAI가 일관되고 신뢰할 수 있는 결과물을 내도록 유도하기 위해 효과적인 프롬프트를 작성하는 재사용 가능한 템플릿입니다. 사내 실무 커뮤니티(CoP)는 정기적인 모임을 통해 성공적인 GenAI 활용 사례를 공유하고, 당면한 과제들을 논의하며, 모범 사례를 개선함으로써 지속적인 지식 공유를 지원합니다. 이러한 커뮤니티는 프롬프트 패턴 라이브러리를 공유하고 다양한 프로젝트와 도메인에서 GenAI를 테스트에 적용하며 얻은 교훈을 문서화함으로써 지속적인 개선을 촉진합니다.

### 5.2.3. AI 지원 테스트 조직에서의 테스트 프로세스 진화

GenAI의 도입은 테스트 조직 내 테스터와 테스트 관리자의 전통적인 테스트 프로세스를 변화시킵니다.

테스터는 단순히 테스트 설계와 수행을 담당하는 전문가에서, 테스트 기법에 대한 전문 지식과 AI가 생성한 테스트웨어를 조율하고 검증하는 능력을 결합한 'AI 지원 테스트 전문가'로 발전합니다. 이들의 테스트 업무는 AI 기반 결과물 전반에 대한 검토, 프롬프트 개선, 테스트에 특화된 프롬프트 라이브러리 유지보수까지 확장됩니다.

테스트 관리자의 책임은 AI 기반 테스트 전략 개발, AI 기반 리스크 관리, AI 기반 테스트 프로세스 모니터링 및 제어로 업데이트됩니다. 테스트 관리자는 인간과 AI 역량의 균형을 맞추고, 사용 사례별 AI 거버넌스 프레임워크를 구축하며, 테스트팀이 전통적인 테스팅 역량과 AI 리터러시를 모두 유지하도록 보장하는 데 집중합니다. 테스트 관리자는 사람으로 구성된 테스터 뿐만 아니라 GenAI 기반 테스트 에이전트와도 협업해야 하므로, 인간과 GenAI 도구로 이루어진 하이브리드 팀을 관리하기 위한 새로운 관리 기술이 요구됩니다.

## 6. 참고 문헌

### Standards

- **ISO/IEC 42001:2023** (2023), Information technology — Artificial intelligence — Management system
- **ISO/IEC 23053:2022** (2022), Framework for Artificial Intelligence (AI) Systems Using Machine Learning (ML)

### ISTQB® Documents

- **[ISTQB\_CTFL\_SYL]** ISTQB® Foundation Level Syllabus v4.0, 2023

### Glossary References

- **ISTQB® Glossary** <https://glossary.istqb.org/>

### Books

- Winteringham M. (2024) Software Testing with Generative AI, Manning Publications (5 Mar. 2025), ISBN-13 : 978-1633437364, 10 Dec. 2024 - 304 pages

### Articles

- (Berthelot 2024) Berthelot, Adrien, et al. "Estimating the environmental impact of Generative-AI services using an LCA-based methodology." *Procedia CIRP* 122 (2024): 707-712.
- (Gallegos 2024) Gallegos, Isabel O., et al. "Bias and fairness in large language models: A survey." *Computational Linguistics* (2024): 1-79.
- (Li 2024) Yihao Li, Pan Liu, Haiyang Wang, Jie Chu, W. Eric Wong, Evaluating Large Language Models for Software Testing, *Computer Standards & Interfaces* (2024), doi: <https://doi.org/10.1016/j.csi.2024.103942>
- (Luccioni 2024a) Luccioni, Sasha, Yacine Jernite, and Emma Strubell. "Power hungry processing: Watts driving the cost of AI deployment?." *The 2024 ACM Conference on Fairness, Accountability, and Transparency*. 2024.
- (Mailach 2024) Mailach, Alina, et al. "Practitioners' Discussions on Building LLM-based Applications for Production." *arXiv preprint arXiv:2411.08574* (2024).
- (Mirzadeh 2024) Mirzadeh, Iman et al. "GSM-Symbolic: Understanding the Limitations of Mathematical Reasoning in Large Language Models." *ArXiv abs/2410.05229* (2024)
- ( NIST AI RMF 1.0) National Institute of Standards and Technology. Artificial Intelligence Risk Management Framework (AI RMF 1.0). NIST AI 100-1, U.S. Department of Commerce, 2023,

<https://doi.org/10.6028/NIST.AI.100-1>.

- (Parthasarathy 2024) Parthasarathy, Venkatesh Balavadhani, et al. "The ultimate guide to fine-tuning llms from basics to breakthroughs: An exhaustive review of technologies, research, best practices, applied research challenges and opportunities." arXiv preprint arXiv:2408.13296 (2024).
- (Schulhoff 2024) Schulhoff, S., "The Prompt Report: A Systematic Survey of Prompting Techniques", Art. no. arXiv:2406.06608, 2024. doi:10.48550/arXiv.2406.06608.
- (Shuyin 2023) Ouyang, Shuyin, et al. "LLM is Like a Box of Chocolates: the Non-determinism of ChatGPT in Code Generation." arXiv preprint arXiv:2308.02828 (2023).
- (Sinha 2024) Sinha, Megha, Sreekanth Menon, and Ram Sagar. "LLMOps: Definitions, Framework and Best Practices." 2024 International Conference on Electrical, Computer and Energy Technologies (ICECET. IEEE, 2024.
- (Wang 2024) Wang, Yanlin, et al. "Agents in Software Engineering: Survey, Landscape, and Vision." arXiv preprint arXiv:2409.09030 (2024).
- (Wenhan 2024) Wang, Wenhan, et al. "TESTEVAL: Benchmarking Large Language Models for Test Case Generation." *arXiv preprint arXiv:2406.04531* (2024).
- (Zhao 2024) Zhao, Penghao, et al. "Retrieval-augmented generation for ai-generated content: A survey." arXiv preprint arXiv:2402.19473 (2024).

## Web Pages

(AI Act 2024) European Commission. "European Approach to Artificial Intelligence." *Shaping Europe's Digital Future*, European Commission, <https://digital-strategy.ec.europa.eu/en/policies/european-approach-artificial-intelligence>. Accessed 24 Nov. 2024.

(Heikkilä 2023) Heikkilä, M. (2023, December 1). Making an image with generative AI uses as much energy as charging your phone. MIT Technology Review. Retrieved from <https://www.technologyreview.com/2023/12/01/1084189/making-an-image-with-generative-ai-uses-as-much-energy-as-charging-your-phone/>

(Luccioni 2024b) Luccioni, S. (2024, February 22). Generative AI's environmental costs are soaring. Nature. Retrieved from <https://www.nature.com/articles/d41586-024-00478-x>

(Google Dev Glossary 2024) Google Developers. (n.d.). Machine learning glossary: Generative AI. Retrieved November 24, 2024, from <https://developers.google.com/machine-learning/glossary/generative>

(MIT 2024) "Glossary of Terms: Generative AI Basics." \*MIT Sloan Teaching & Learning Technologies\*, MIT Sloan School of Management, <https://mitsloanedtech.mit.edu/ai/basics/glossary>. Accessed 24 Nov. 2024.

The previous references point to information available on the Internet and elsewhere. Even though those references were checked at the time of publication of this syllabus, the ISTQB® cannot be held responsible if the references are not available anymore.

## 부록 A – 학습 목표/인지 지식 수준

이 실러버스에 적용되는 구체적인 학습 목표는 각 장의 시작 부분에 나와 있습니다. 실러버스의 각 주제는 해당 학습 목표에 따라 평가됩니다.

학습 목표는 아래에 나열된 인지적 지식 수준에 해당하는 동작 동사(Action verb)로 시작합니다.

### 레벨 1: 기억하기 (K1)

참가자는 용어나 개념을 기억하고, 인식하며, 상기할 수 있어야 합니다.

**Action Verb:** 상기하다, 인식하다.

| 예시                  |
|---------------------|
| 테스트 피라미드의 개념을 상기한다. |
| 테스팅의 일반적인 목표를 인식한다. |

### 레벨 2: 이해하기 (K2)

참가자는 주제와 관련된 진술에 대한 이유나 설명을 선택할 수 있고, 테스팅 개념에 대해 요약, 비교, 분류, 예시들기를 할 수 있어야 합니다.

**Action Verb:** 분류하다, 비교하다, 구별하다, 구분하다, 설명하다, 예시를 들다, 추론하다, 요약하다.

| 예시                                | 참고                                   |
|-----------------------------------|--------------------------------------|
| 목적과 지원하는 테스트 활동에 따라 테스트 도구를 분류한다. |                                      |
| 여러 테스트 레벨을 비교한다.                  | 유사점, 차이점 또는 둘 다를 찾는 데 사용될 수 있다.      |
| 테스팅과 디버깅을 구별한다.                   | 개념 간의 차이점을 찾는다.                      |
| 프로젝트 리스크와 제품 리스크를 구분한다.           | 두 개(또는 그 이상)의 개념을 개별적으로 분류할 수 있게 한다. |
| 컨텍스트가 테스트 프로세스에 미치는 영향을 설명한다.     |                                      |
| 테스팅이 필요한 이유에 대한 예시를 든다.           |                                      |
| 제공된 실패한 프로파일로부터 결함의 근본 원인을 추론한다.  |                                      |
| 작업 산출물 검토 프로세스의 활동을 요약한다.         |                                      |

### 레벨 3: 적용하기 (K3)

참가자는 익숙한 과제에 직면했을 때 절차를 수행하거나, 올바른 절차를 선택해 주어진 컨텍스트에 적용할 수 있어야 합니다.

**Action Verb:** 적용하다, 구현하다, 준비하다, 사용하다.

| 예시                                                                  | 참고                                                         |
|---------------------------------------------------------------------|------------------------------------------------------------|
| 주어진 요구사항에서 테스트 케이스를 도출하기 위해 경계값 분석을 적용한다.                           | 절차/기법/프로세스 등을 참조해야 한다.                                     |
| 기술적, 관리적 요구사항을 지원하기 위해 메트릭 수집 방법을 구현한다.                             |                                                            |
| 모바일 앱에 대한 설치성 테스트를 준비한다.                                            |                                                            |
| 테스트 목표, 테스트 전략, 테스트 계획과의 완전성과 일관성을 위해 테스트 진행 상황을 모니터링하는데 추적성을 사용한다. | 후보자가 기법이나 절차를 사용할 수 있기를 원하는 LO 에서 사용될 수 있으며, '적용하다'와 유사하다. |

#### 참고문헌

(인지 학습 수준에 대해)

Anderson, L. W. and Krathwohl, D. R. (eds) (2001) A Taxonomy for Learning, Teaching, and Assessing: A Revision of Bloom's Taxonomy of Educational Objectives, Allyn & Bacon

## 부록 B – 비즈니스 성과와 학습 목표 추적성 매트릭스

이 섹션은 생성형 AI 활용 테스트(CT-GenAI)의 예상 비즈니스 성과(BO: Business Outcomes)와 학습 목표(LO: Learning Objectives) 간의 추적성을 나열합니다. 각 HO는 단일 LO와 연관되어 있기 때문에 실습 목표(HO: Hands-on objectives)는 이 표에 언급되지 않았습니다. HO와 BO 간의 추적성은 HO가 연관된 LO를 통해 이루어집니다.

| 생성형 AI 활용 테스트(CT-GenAI)의 예상 비즈니스 성과 |                                                        |                | BO1 | BO2 | BO3 | BO4 | BO5 |
|-------------------------------------|--------------------------------------------------------|----------------|-----|-----|-----|-----|-----|
| GenAI-BO1                           | 생성형 AI의 기본 개념, 역량, 한계를 이해한다.                           |                | 8   |     |     |     |     |
| GenAI-BO2                           | 소프트웨어 테스트를 위해 거대 언어 모델을 프롬프팅하는 실용적인 기술을 개발한다.          |                |     | 10  |     |     |     |
| GenAI-BO3                           | 소프트웨어 테스트에 생성형 AI를 사용할 때의 리스크와 완화 방안에 대한 통찰력을 얻는다.     |                |     |     | 11  |     |     |
| GenAI-BO4                           | 소프트웨어 테스트를 위한 생성형 AI 솔루션의 적용 사례에 대한 통찰력을 얻는다.          |                |     |     |     | 19  |     |
| GenAI-BO5                           | 조직 내 소프트웨어 테스트를 위한 생성형 AI 전략과 로드맵의 정의와 구현에 효과적으로 기여한다. |                |     |     |     |     | 13  |
| <b>Unique LO</b>                    | <b>학습 목표 (LO: Learning Objectives)</b>                 | <b>K-Level</b> |     |     |     |     |     |
| 1                                   | 소프트웨어 테스트를 위한 생성형 AI 소개                                |                |     |     |     |     |     |
| 1.1                                 | 생성형 AI의 기초 및 핵심 개념                                     |                |     |     |     |     |     |
| GenAI-1.1.1                         | AI의 여러 유형(심볼릭 AI, 고전적 머신 러닝, 딥 러닝, 생성형 AI)을 상기한다.      | K1             | X   |     |     |     |     |
| GenAI-1.1.2                         | 생성형 AI와 거대 언어 모델의 기초를 설명한다.                            | K2             | X   |     |     |     |     |
| GenAI-1.1.3                         | 파운데이션, 명령어 튜닝 및 추론 LLM을 구별한다.                          | K2             | X   |     |     |     |     |
| GenAI-1.1.4                         | 멀티모달 LLM과 비전-언어 모델의 기본 원칙을 요약한다.                       | K2             | X   |     |     |     |     |
| 1.2                                 | 소프트웨어 테스트에서 생성형 AI 활용: 핵심 원칙                           |                |     |     |     |     |     |
| GenAI-1.2.1                         | 테스트 작업을 위한 LLM 역량의 예를 든다.                              | K2             | X   |     |     | X   |     |

| 생성형 AI 활용 테스트(CT-GenAI)의 예상 비즈니스 성과 |                                                         |    | BO1 | BO2 | BO3 | BO4 | BO5 |
|-------------------------------------|---------------------------------------------------------|----|-----|-----|-----|-----|-----|
| GenAI-1.2.2                         | 소프트웨어 테스트에서 GenAI 를 사용할 때의 상호작용 모델을 비교한다.               | K2 | X   |     |     | X   |     |
| 2                                   | 효과적인 소프트웨어 테스트를 위한 프롬프트 엔지니어링                           |    |     |     |     |     |     |
| 2.1                                 | 효과적인 프롬프트 개발                                            |    |     |     |     |     |     |
| GenAI-2.1.1                         | 소프트웨어 테스트에서 생성형 AI 에 사용되는 프롬프트 구조의 예를 든다.               | K2 |     | X   |     |     |     |
| GenAI-2.1.2                         | 소프트웨어 테스트를 위한 핵심 프롬프팅 기법을 구별한다.                         | K2 |     | X   |     |     |     |
| GenAI-2.1.3                         | 시스템 프롬프트와 사용자 프롬프트를 구별한다.                               | K2 |     | X   |     |     |     |
| 2.2                                 | 소프트웨어 테스트 작업에 프롬프트 엔지니어링 기법 적용하기                        |    |     |     |     |     |     |
| GenAI-2.2.1                         | 테스트 분석 작업에 생성형 AI 를 적용한다.                               | K3 |     | X   |     |     |     |
| GenAI-2.2.2                         | 테스트 설계 및 구현 작업에 생성형 AI 를 적용한다.                          | K3 |     | X   |     |     |     |
| GenAI-2.2.3                         | 자동화된 리그레션 테스트에 생성형 AI 를 적용한다.                           | K3 |     | X   |     |     |     |
| GenAI-2.2.4                         | 테스트 모니터링 작업을 위해 생성형 AI 를 적용한다.                          | K3 |     | X   |     |     |     |
| GenAI-2.2.5                         | 주어진 컨텍스트와 테스트 작업에 적합한 프롬프팅 기법을 선택하고 적용한다.               | K3 |     | X   |     | X   |     |
| 2.3                                 | 생성형 AI 결과 평가 및 소프트웨어 테스트 작업을 위한 프롬프트 개선                 |    |     |     |     |     |     |
| GenAI-2.3.1                         | 테스트 작업에 대한 생성형 AI 결과 평가 메트릭을 이해한다.                      | K2 |     | X   | X   | X   |     |
| GenAI-2.3.2                         | 프롬프트를 평가하고 반복적으로 개선하는 방법에 대한 예를 든다.                     | K2 |     | X   | X   | X   |     |
| 3                                   | 소프트웨어 테스트에서 생성형 AI 의 리스크 관리                             |    |     |     |     |     |     |
| 3.1                                 | 환각, 추론 오류, 편향                                           |    |     |     |     |     |     |
| GenAI-3.1.1                         | 생성형 AI 시스템에서 환각, 추론 오류, 편향의 정의를 상기하다.                   | K1 | X   |     | X   | X   |     |
| GenAI-3.1.2                         | LLM 출력에서 환각, 추론 오류, 편향을 분석한다.                           | K3 |     |     | X   | X   |     |
| GenAI-3.1.3                         | 소프트웨어 테스트 작업에서 GenAI 환각, 추론 오류, 편향에 대한 완화 기법을 요약한다.     | K2 |     |     | X   | X   |     |
| GenAI-3.1.4                         | LLM 의 비결정론적 행동에 대한 완화 기법을 상기하다.                         | K1 | X   |     | X   | X   |     |
| 3.2                                 | 소프트웨어 테스트에서 생성형 AI 의 데이터 프라이버시 및 보안 리스크                 |    |     |     |     |     |     |
| GenAI-3.2.1                         | 소프트웨어 테스트에서 생성형 AI 사용과 관련된 주요 데이터 프라이버시 및 보안 리스크를 설명한다. | K2 |     |     | X   | X   |     |

| 생성형 AI 활용 테스트(CT-GenAI)의 예상 비즈니스 성과 |                                                               |    | BO1 | BO2 | BO3 | BO4 | BO5 |
|-------------------------------------|---------------------------------------------------------------|----|-----|-----|-----|-----|-----|
| GenAI-3.2.2                         | 소프트웨어 테스트에서 생성형 AI 를 사용할 때의 데이터 프라이버시 및 취약점의 예를 든다.           | K2 |     |     | X   | X   |     |
| GenAI-3.2.3                         | 소프트웨어 테스트에서 생성형 AI 의 데이터 프라이버시를 보호하고 보안을 강화하기 위한 완화 전략을 요약한다. | K2 |     |     | X   | X   |     |
| 3.3                                 | 소프트웨어 테스트에서 생성형 AI 의 에너지 소비와 환경 영향                            |    |     |     |     |     |     |
| GenAI-3.3.1                         | 작업 특성과 모델 사용이 소프트웨어 테스트에서 생성형 AI 의 에너지 소비에 미치는 영향을 설명한다.      | K2 |     |     | X   | X   |     |
| 3.4                                 | AI 규정, 표준 및 모범 사례 프레임워크                                       |    |     |     |     |     |     |
| GenAI-3.4.1                         | 소프트웨어 테스트에서 GenAI 와 관련된 AI 규정, 표준, 모범 사례 프레임워크의 예를 상기한다.      | K1 |     |     | X   | X   | X   |
| 4                                   | 소프트웨어 테스트를 위한 LLM 기반 테스트 인프라                                  |    |     |     |     |     |     |
| 4.1                                 | LLM 기반 테스트 인프라를 위한 아키텍처 접근법                                   |    |     |     |     |     |     |
| GenAI-4.1.1                         | LLM 기반 테스트 인프라의 주요 아키텍처 구성요소와 개념을 설명한다.                       | K2 |     |     |     | X   | X   |
| GenAI-4.1.2                         | 검색 증강 생성을 요약한다.                                               | K2 |     |     |     | X   | X   |
| GenAI-4.1.3                         | 테스트 프로세스 자동화에서 LLM 기반 에이전트의 역할과 적용을 설명한다.                     | K2 |     |     |     | X   | X   |
| 4.2                                 | 미세 조정과 LLMOps: 소프트웨어 테스트를 위한 생성형 AI 운영화                       |    |     |     |     |     |     |
| GenAI-4.2.1                         | 특정 테스트 작업을 위한 언어 모델의 미세 조정을 설명한다.                             | K2 |     |     |     | X   | X   |
| GenAI- 4.2.2                        | LLMOps 와 테스트 작업을 위한 LLM 배포 및 관리에서의 역할을 설명한다.                  | K2 |     |     |     | X   | X   |
| 5                                   | 테스트 조직에서 생성형 AI 배포 및 통합                                       |    |     |     |     |     |     |
| 5.1                                 | 소프트웨어 테스트에서 생성형 AI 도입을 위한 로드맵                                 |    |     |     |     |     |     |
| GenAI-5.1.1                         | 새도우 AI 의 리스크를 상기한다.                                           | K1 |     |     |     |     | X   |
| GenAI-5.1.2                         | 소프트웨어 테스트를 위한 생성형 AI 전략 수립 시 고려해야 할 주요 측면을 설명한다.              | K2 |     |     |     |     | X   |
| GenAI-5.1.3                         | 주어진 컨텍스트에서 소프트웨어 테스트 작업을 위한 LLM/SLM 선택의 주요 기준을 요약한다.          | K2 |     |     |     |     | X   |

| 생성형 AI 활용 테스트(CT-GenAI)의 예상 비즈니스 성과 |                                                                |    | BO1 | BO2 | BO3 | BO4 | BO5 |
|-------------------------------------|----------------------------------------------------------------|----|-----|-----|-----|-----|-----|
| GenAI-5.1.4                         | 테스트 조직에서 생성형 AI 도입의 주요 단계를 상기한다.                               | K1 |     |     |     |     | X   |
| 5.2                                 | 소프트웨어 테스트에 생성형 AI 도입 시 변화 관리                                   |    |     |     |     |     |     |
| GenAI-5.2.1                         | 테스터가 테스트 프로세스에서 생성형 AI 와 효과적으로 작업하기 위해 필요한 필수 기술과 지식 영역을 설명한다. | K2 |     |     |     |     | X   |
| GenAI-5.2.2                         | 테스트 활동에서 생성형 AI 도입을 지원하기 위해 테스트팀 내에서 AI 기술을 배양하는 전략을 상기한다.     | K1 |     |     |     |     | X   |
| GenAI-5.2.3                         | 생성형 AI 도입 시 테스트 조직 내에서 테스트 프로세스와 책임이 어떻게 변하는지 인식한다.            | K1 |     |     |     |     | X   |

## 부록 D - 생성형 AI 특정 용어

| 용어                                              | 정의                                                                                    |
|-------------------------------------------------|---------------------------------------------------------------------------------------|
| <b>AI 챗봇 (AI chatbot)</b>                       | LLM 을 사용해 쿼리를 처리하고 인간과 유사한 텍스트 응답을 생성해 사용자와의 대화형 소통을 가능하게 하는 대화형 에이전트.                |
| <b>컨텍스트 창 (Context window)</b>                  | 언어 모델이 응답을 생성할 때 고려하는 토큰 단위로 측정된 텍스트의 범위로, 출력의 일관성과 연관성에 영향을 미침.                      |
| <b>딥 러닝(Deep learning)</b>                      | 다수의 계층을 가진 신경망을 사용하는 머신 러닝.                                                           |
| <b>임베딩 (Embedding)</b>                          | 의미적, 구문적, 문맥적 관계를 포착하도록 훈련 중에 단일 공간 내의 밀집 벡터로 토큰을 표현하는 데 사용되는 기법.                     |
| <b>피쳐 (Feature)</b>                             | 머신 러닝 알고리즘에 의한 훈련과 머신 러닝 모델의 예측에 사용되는 입력 데이터의 개별적인 측정 가능한 속성.                         |
| <b>퓨샷 프롬프팅 (Few-shot prompting)</b>             | 모델이 적절한 응답을 생성하도록 유도하기 위해 프롬프트 내에 몇 가지 예시를 제공하는 기법.                                   |
| <b>미세 조정 (Fine-tuning / 파인튜닝)</b>               | LLM 의 가중치를 업데이트하고 이를 특정 작업이나 도메인에 맞춤화하기 위해 레이블이 지정된 예시 데이터셋을 사용하는 지도 학습 프로세스.         |
| <b>파운데이션 LLM (Foundation LLM)</b>               | 광범위한 텍스트 데이터로 사전 훈련된 범용 모델로, 학습된 언어 패턴을 기반으로 다음 단어를 예측할 수 있음. 동의어: 기본 LLM (Base LLM). |
| <b>생성형 AI (Generative AI / GenAI)</b>           | 머신 러닝 모델을 사용하여 인간이 생성한 콘텐츠와 유사한 (새로운) 지적 콘텐츠를 생성하는 인공지능 시스템의 한 종류.                    |
| <b>GPT (Generative pre-trained transformer)</b> | 인간과 유사한 텍스트를 이해하고 생성하도록 방대한 양의 텍스트 데이터로 사전 학습된 트랜스포머 기반의 딥러닝 모델 유형.                   |
| <b>환각(Hallucination)</b>                        | LLM 에 의해 생성된 잘못된 정보.                                                                  |
| <b>명령어 튜닝 LLM (Instruction-tuned LLM)</b>       | 지침을 따르도록 훈련된 파운데이션 LLM 으로, 종종 정확한 답변을 장려하기 위해 피드백으로 강화됨.                              |
| <b>거대 언어 모델 (Large language model / LLM)</b>    | 인간과 유사한 방식으로 텍스트를 이해하고 생성하기 위해 매우 방대한 언어 데이터 집합을 사용하는 컴퓨터 프로그램.                       |
| <b>LLM 기반 에이전트 (LLM-powered agent)</b>          | 도구를 사용해 작업을 수행하며, LLM 의 추론, 의사 결정, 메모리 기능을 통합한 애플리케이션.                                |
| <b>LLMOps</b>                                   | 프로덕션 환경에서 LLM 을 배포, 모니터링, 유지 관리하는 데 초점을 맞춘 실천법과 도구.                                   |
| <b>머신 러닝 (machine learning / ML)</b>            | 시스템이 데이터나 경험으로부터 학습할 수 있도록 컴퓨팅 기술을 사용하는 프로세스 (ISO/IEC TR 29119-11).                   |
| <b>메타 프롬프팅 (Meta prompting)</b>                 | 기능 탐색 또는 자동화를 위해 특정 프롬프트를 생성하는 상위 수준의 지시어를 작성하는 것.                                    |
| <b>멀티모달 모델 (Multimodal model)</b>               | 텍스트, 이미지, 오디오와 같은 여러 데이터 유형에 걸쳐 콘텐츠를 처리하고 생성할 수 있는 GenAI 모델.                          |

| 용어                                                    | 정의                                                                                               |
|-------------------------------------------------------|--------------------------------------------------------------------------------------------------|
| <b>자연어 처리</b><br>(natural language processing / NLP)  | 정보 검색 및 지식 표현을 위해 컴퓨터가 자연어로 인코딩된 데이터를 처리하는 것.                                                    |
| <b>원샷 프롬프팅</b><br>(One-shot prompting)                | LLM의 응답을 유도하기 위해 프롬프트에 하나의 예제를 포함하는 프롬프트 작성 기법.                                                  |
| <b>프롬프트 (Prompt)</b>                                  | 생성형 AI 및 거대 언어 모델에서 특정 응답을 유도하기 위해 제공되는 자연어 입력.                                                  |
| <b>프롬프트 체이닝</b><br>(Prompt chaining)                  | 하나의 프롬프트 출력을 다른 프롬프트의 입력으로 사용해 프롬프트 시퀀스를 만드는 프롬프팅 기법.                                            |
| <b>프롬프트 엔지니어링</b><br>(Prompt engineering)             | LLM이 원하는 출력을 생성하도록 유도하기 위해 입력 프롬프트를 설계하고 개선하는 프로세스.                                              |
| <b>추론 LLM</b><br>(Reasoning LLM)                      | 명령어 튜닝 모델을 기반으로 구축되어, 인간과 유사한 추론 프로세스를 모방하는 능력을 개선한 LLM.                                         |
| <b>검색 증강 생성 (RAG: Retrieval-augmented generation)</b> | 정확하고 문맥적으로 관련 있는 응답을 생성하기 위해 연관 데이터를 가져오는 검색기와 LLM의 역량을 결합하는 기법.                                 |
| <b>새도우 AI</b><br>(Shadow AI)                          | 공식적인 승인이나 감독 없이 조직 내에서 GenAI 도구나 시스템을 사용하는 것.                                                    |
| <b>소형 언어 모델 (SLM: Small language model)</b>           | 효율성과 작업별 언어 이해 사이의 균형을 제공하도록 의도적으로 작게 설계되고 훈련된 언어 모델.                                            |
| <b>심볼릭 AI</b><br>(Symbolic AI)                        | 추론을 모델링하기 위해 기호, 규칙, 구조화된 지식을 사용하는 AI 접근 방식.                                                     |
| <b>시스템 프롬프트</b><br>(System prompt)                    | 일반적으로 챗봇 사용자에게는 숨겨져 있으며, LLM의 응답에 대한 컨텍스트, 톤, 경계를 일관되게 설정하고 상호작용 전반에 걸쳐 그 행동을 안내하는 사전 정의된 지침 세트. |
| <b>온도</b><br>(Temperature / 템퍼러처)                     | LLM 출력의 무작위성이나 창의성을 제어하는 파라미터.                                                                   |
| <b>토큰화</b><br>(Tokenization)                          | 언어 모델이 처리할 수 있도록 텍스트를 더 작은 단위로 분할하는 프로세스.                                                        |
| <b>트랜스포머</b><br>(Transformer)                         | 입력 시퀀스에서 장기 의존성을 포착하기 위해 Self-attention 메커니즘을 활용하는 딥 러닝 모델 아키텍처.                                 |
| <b>사용자 프롬프트</b><br>(User prompt)                      | 특정 작업을 수행하거나 원하는 정보를 제공하도록 모델의 응답을 유도하기 위해 사용자가 거대 언어 모델(LLM)에 입력하는 지침이나 쿼리.                     |
| <b>벡터 데이터베이스</b><br>(Vector database)                 | 데이터의 고차원 벡터 표현을 저장하고 쿼리하는 데 최적화된 데이터베이스.                                                         |
| <b>비전-언어 모델</b><br>(Vision-language model)            | 두 양식(modalities)에 걸쳐 콘텐츠를 연결하고 생성함으로써 작업을 수행하기 위해 시각 및 텍스트 데이터를 결합해 함께 처리하는 GenAI 시스템.           |
| <b>제로샷 프롬프팅</b><br>(Zero-shot prompting)              | 응답을 생성하기 위해 모델의 기존 지식에만 의존하며, 프롬프트에 아무런 예제도 포함하지 않는 프롬프트 작성 기법.                                  |

|                   |  |
|-------------------|--|
| <b>부록 E – 상표권</b> |  |
|-------------------|--|

ISTQB® is a registered trademark of International Software Testing Qualifications Board